مدرسة علوم المعلومات
ⵜⴰⵙⴷⴰⵡⵉⵜ ⵏ ⵜⵎⴰⵙⵙⴰⵏⵉⵏ ⴷ ⵓⵙⵉⵍⵎⴷ
ECOLE DES SCIENCES DE L'INFORMATION

- Fait par:

➢MAATI Manal

➢ERROUSSO Douae

➢SELOUANI Omar __

➢SADOUK Youness

1. Introduction

Le Football, avec sa popularité mondiale, transcende les barrières culturelles et linguistiques, rassemblant des millions de fans autour d'un événement: la Coupe du Monde de la FIFA. La Coupe du Monde, qui se tient tous les quatre ans, est le summum de la compétition de football international, mettant en lumière les meilleurs pays et joueurs du monde entier. À travers les décennies, cet événement a observé l'évolution du jeu, des performances remarquables des équipes aux exploits individuels de joueurs légendaires.

Dans le cadre de ce projet, nous analyserons trois ensembles de données: worldcups.csv, worldcupmatches.csv, et worldcuplayers.csv.

Chacun de ces ensembles de données joue un rôle crucial dans l'exploration de l'histoire et des dynamiques de la Coupe du Monde.

2. Etude avec R sur la dataset “WorldCups.csv”:

- Préparation des données:

❖ import de la dataset:

```
fifa_wc <- read.csv("WorldCups.csv")
```

```
str(fifa_wc)
```

```
'data.frame':   20 obs. of  10 variables:
 $ Year          : int  1930 1934 1938 1950 1954 1958 1962 1966 1970 1974 ...
 $ Country       : chr  "Uruguay" "Italy" "France" "Brazil" ...
 $ Winner        : chr  "Uruguay" "Italy" "Italy" "Uruguay" ...
 $ Runners.Up    : chr  "Argentina" "Czechoslovakia" "Hungary" "Brazil" ...
 $ Third         : chr  "USA" "Germany" "Brazil" "Sweden" ...
 $ Fourth        : chr  "Yugoslavia" "Austria" "Sweden" "Spain" ...
 $ GoalsScored   : int  70 70 84 88 140 126 89 89 95 97 ...
 $ QualifiedTeams: int  13 16 15 13 16 16 16 16 16 16 ...
 $ MatchesPlayed : int  18 17 18 22 26 35 32 32 32 38 ...
 $ Attendance    : chr  "590.549" "363.000" "375.700" "1.045.246" ...
```

Les colonnes de la dataset incluent :
Year (Année) : Les années de chaque tournoi, allant de 1930 à 1974 dans l'extrait affiché.
Country (Pays) : Le pays hôte de chaque tournoi.
Winner (Vainqueur) : Le pays gagnant du tournoi.
Runners.Up (Finaliste) : Le pays finaliste, arrivé en deuxième place.
Third (Troisième) : Le pays arrivé en troisième place.
Fourth (Quatrième) : Le pays arrivé en quatrième place.
GoalsScored (Buts marqués) : Le nombre de buts marqués dans chaque tournoi.
QualifiedTeams (Équipes qualifiées) : Le nombre d’équipes qualifiées pour chaque édition.
MatchesPlayed (Matchs joués) : Le nombre de matchs joués lors de chaque tournoi.
Attendance (Affluence) : Le nombre de spectateurs, affiché dans un format de chaîne de caractères avec des points pour séparer les milliers (par exemple, "590.549").

❖ Gestion des valeurs manquantes

```
colSums(is.na(fifa_wc))
```

```
Year:          0 Country:       0 Winner:        0 Runners.Up:    0 Third:         0 Fourth:        0 GoalsScored:   0 QualifiedTeams:  0 MatchesPlayed:   0 Attendance:   14
```

On voit que toutes les colonnes sauf Attendance n'ont aucune valeur manquante. La colonne Attendance a 14 valeurs manquantes

```
fifa_wc$Attendance <- as.numeric(gsub(",", "", fifa_wc$Attendance))
```

On a convertit la variable Attendance en une variable numérique.

- Analyse unidimensionnelle:
  - Connaitre la dataset

```
head(fifa_wc, 5)
#fifa_wc[1:10, ]
```

A data.frame: 5 × 10

	Year	Country	Winner	Runners.Up	Third	Fourth	GoalsScored	QualifiedTeams	MatchesPlayed	Attendance
	<int>	<chr>	<chr>	<chr>	<chr>	<chr>	<int>	<int>	<int>	<chr>
1	1930	Uruguay	Uruguay	Argentina	USA	Yugoslavia	70	13	18	590.549
2	1934	Italy	Italy	Czechoslovakia	Germany	Austria	70	16	17	363.000
3	1938	France	Italy	Hungary	Brazil	Sweden	84	15	18	375.700
4	1950	Brazil	Uruguay	Brazil	Sweden	Spain	88	13	22	1.045.246
5	1954	Switzerland	Germany FR	Hungary	Austria	Uruguay	140	16	26	768.607

```
tail(fifa_wc, 5)
#fifa_wc[(nrow(fifa_wc) - 4):nrow(fifa_wc), ]
```

A data.frame: 5 × 10

	Year	Country	Winner	Runners.Up	Third	Fourth	GoalsScored	QualifiedTeams	MatchesPlayed	Attendance
	<int>	<chr>	<chr>	<chr>	<chr>	<chr>	<int>	<int>	<int>	<chr>
16	1998	France	France	Brazil	Croatia	Netherlands	171	32	64	2.785.100
17	2002	Korea/Japan	Brazil	Germany	Turkey	Korea Republic	161	32	64	2.705.197
18	2006	Germany	Italy	France	Germany	Portugal	147	32	64	3.359.439
19	2010	South Africa	Spain	Netherlands	Germany	Uruguay	145	32	64	3.178.856
20	2014	Brazil	Germany	Argentina	Netherlands	Brazil	171	32	64	3.386.810

Ces deux code nous montre les 5 premières et les 5 dernières lignes d'un dataframe nommé "fifa_wc".

```
mode_class <- list(mode = mode(fifa_wc), class = class(fifa_wc))
print(mode_class)
```

```
$mode
[1] "list"

$class
[1] "data.frame"
```

```
dim(fifa_wc)
```

```
20 · 10
```

Le fait que `fifa_wc` soit une data frame avec une structure de liste signifie qu'il s'agit d'un tableau de données organisé en colonnes, où chaque colonne peut contenir un type de données spécifique.

```
summary(fifa_wc)
```

```
      Year        Country             Winner           Runners.Up
 Min.   :1930   Length:20          Length:20          Length:20
 1st Qu.:1957   Class :character   Class :character   Class :character
 Median :1976   Mode  :character   Mode  :character   Mode  :character
 Mean   :1975
 3rd Qu.:1995
 Max.   :2014

    Third              Fourth           GoalsScored     QualifiedTeams
 Length:20          Length:20          Min.   : 70.0   Min.   :13.00
 Class :character   Class :character   1st Qu.: 89.0   1st Qu.:16.00
 Mode  :character   Mode  :character   Median :120.5   Median :16.00
                                       Mean   :119.0   Mean   :21.25
                                       3rd Qu.:145.2   3rd Qu.:26.00
                                       Max.   :171.0   Max.   :32.00

 MatchesPlayed    Attendance
 Min.   :17.0   Min.   :363.0
 1st Qu.:30.5   1st Qu.:429.4
 Median :38.0   Median :679.6
 Mean   :41.8   Mean   :635.1
 3rd Qu.:55.0   3rd Qu.:807.0
 Max.   :64.0   Max.   :893.2
                NA's   :14
```

Ce résumé donne une vue d'ensemble des valeurs minimales, maximales, moyennes et des valeurs des quartiles pour les variables numériques, tandis que les variables catégorielles montrent seulement des informations de type et de longueur.

```
quantitative_data <- fifa_wc[, sapply(fifa_wc, is.numeric)]
print(quantitative_data)
```

```
qualitative_data <- fifa_wc[, sapply(fifa_wc, function(x) is.factor(x) || is.character(x))]
print(qualitative_data)
```

on a separer entre les variables quantitatives et qualitatives

```r
mean_goals <- mean(fifa_wc$GoalsScored)
median_goals <- median(fifa_wc$GoalsScored)
quartiles_goals <- quantile(fifa_wc$GoalsScored)
list(mean = mean_goals, median = median_goals, quartiles = quartiles_goals)
```

```
$mean
      118.95
$median
      120.5
$quartiles
      0%:      70 25%:      89 50%:      120.5 75%:      145.25 100%:      171
```

La moyenne des buts marqués est de 118,95. Cela signifie que, statistiquement, le nombre moyen de buts dans cet ensemble de données est d'environ 119.La médiane est de 120,5. Cela signifie que la moitié des observations de GoalsScored sont inférieures ou égales à 120,5 et l'autre moitié est supérieure ou égale à cette valeur.1er quartile (Q1, 25%) : 89 buts. Cela signifie que 25% des observations sont inférieures ou égales à 89. C'est la limite inférieure d'un groupe de 25% des valeurs les plus faibles.

2e quartile (Q2 ou médiane, 50%) : 120,5 buts (comme la médiane). Cela signifie que 50% des données sont en dessous de cette valeur.

3e quartile (Q3, 75%) : 145,25 buts. Cela signifie que 75% des données sont inférieures ou égales à 145,25, et les 25% restants sont au-dessus.

Minimum (0%) : 70 buts. C'est la valeur la plus basse dans l'ensemble de données.

Maximum (100%) : 171 buts. C'est la valeur la plus haute dans l'ensemble de données.

```r
# le mode
mode_variable <- mfv(fifa_wc$Winner)
print("mode pour winner")
print(mode_variable)
```

```
[1] "mode pour winner"
[1] "Brazil"
```

Le mode de la variable `Winner` étant "Brazil" signifie que, parmi les données disponibles, le Brésil est l'équipe qui a remporté le plus souvent la Coupe du Monde FIFA.

```r
#min, max, IQR, variance et écart-type
print("min, max, IQR, variance et écart-type de GoalsScored")
min_goals <- min(fifa_wc$GoalsScored)
max_goals <- max(fifa_wc$GoalsScored)
iqr_goals <- IQR(fifa_wc$GoalsScored)
var_goals <- var(fifa_wc$GoalsScored)
sd_goals <- sd(fifa_wc$GoalsScored)
list(min = min_goals, max = max_goals, IQR = iqr_goals, variance = var_goals, sd = sd_goals)
```

```
[1] "min, max, IQR, variance et écart-type de GoalsScored"

$min
      70
$max
      171
$IQR
      56.25
$variance
      1087.20789473684
$sd
      32.9728357096693
```

1. Minimum (min) = 70

- Cela indique que la plus petite valeur de "GoalsScored" dans l'ensemble de données est 70.

2. Maximum (max) = 171
    - Cela indique que la plus grande valeur de "GoalsScored" dans l'ensemble de données est 171.
3. Écart interquartile (IQR) = 56.25
    - Une valeur d'IQR de 56.25 suggère une dispersion modérée des valeurs autour de la médiane.
4. Variance = 1087.2078947368
    - Une variance élevée de 1087.2078947368 indique une dispersion importante des données.
5. Écart-type (sd) = 32.97283570966693
    - Une valeur d'écart-type de 32.97283570966693 corrobore une forte dispersion des données autour de la moyenne.

ces statistiques suggèrent que les valeurs de "GoalsScored" dans cet ensemble de données présentent une plage assez étendue, avec une dispersion importante autour de la moyenne. Cela pourrait indiquer une variabilité élevée des performances de but dans les données.

```r
# le coefficient d'aplatissement
kurtosis_goals <- kurtosis(fifa_wc$GoalsScored)
print("kurtosis goals")
print(kurtosis_goals)
```

```
[1] "kurtosis goals"
[1] 1.688768
```

```r
#le coefficient d'asymétrie
skewness_goals <- skewness(fifa_wc$GoalsScored)
print("skewness goals")
print(skewness_goals)
```

```
[1] "skewness goals"
[1] 0.07328152
```

- Une skewness de 0.07328152 indique que la distribution est légèrement asymétrique vers la droite, avec une queue plus épaisse du côté des valeurs élevées.
- Cela signifie que la majorité des valeurs sont concentrées vers la gauche de la distribution, avec quelques valeurs plus élevées s'étendant vers la droite.
- Une valeur de kurtosis de 1.688 suggère une distribution légèrement plus aplatie que la normale (distribution mésokurtique).
- Cela indique que la distribution a des queues plus fines et une concentration des valeurs autour de la moyenne, par rapport à une distribution normale.
    - Analyse unidimensionnelle:

```r
#Qualitative vs qualitative
table_contingency <- table(fifa_wc$Winner, fifa_wc$Runners.Up)
print("contingency table for Winner and Runner Up")
print(table_contingency)
```

```
[1] "contingency table for Winner and Runner Up"

            Argentina Brazil Czechoslovakia France Germany Germany FR Hungary
  Argentina         0      0              0      0       0          1       0
  Brazil            0      0              1      0       1          0       0
  England           0      0              0      0       0          1       0
  France            0      1              0      0       0          0       0
  Germany           1      0              0      0       0          0       0
  Germany FR        1      0              0      0       0          0       1
  Italy             0      0              1      1       0          1       1
  Spain             0      0              0      0       0          0       0
  Uruguay           1      1              0      0       0          0       0

            Italy Netherlands Sweden
  Argentina     0           1      0
  Brazil        2           0      1
  England       0           0      0
  France        0           0      0
  Germany       0           0      0
  Germany FR    0           1      0
  Italy         0           0      0
  Spain         0           1      0
  Uruguay       0           0      0
```

Le tableau de contingence montre le nombre de victoires et de places de finaliste pour chaque pays ayant participé à la Coupe du Monde de la FIFA. Par exemple, l'Argentine a remporté la Coupe du Monde 1 fois et a été finaliste 0 fois, tandis que le Brésil l'a remportée 0 fois et a été finaliste 2 fois.

```r
marginal_frequency <- addmargins(table_contingency)
print("marginal frequency for table contingency")
print(marginal_frequency)
```

```
[1] "marginal frequency for table contingency"

            Argentina Brazil Czechoslovakia France Germany Germany FR Hungary
  Argentina         0      0              0      0       0          1       0
  Brazil            0      0              1      0       1          0       0
  England           0      0              0      0       0          1       0
  France            0      1              0      0       0          0       0
  Germany           1      0              0      0       0          0       0
  Germany FR        1      0              0      0       0          0       1
  Italy             0      0              1      1       0          1       1
  Spain             0      0              0      0       0          0       0
  Uruguay           1      1              0      0       0          0       0
  Sum               3      2              2      1       1          3       2

            Italy Netherlands Sweden Sum
  Argentina     0           1      0   2
  Brazil        2           0      1   5
  England       0           0      0   1
  France        0           0      0   1
  Germany       0           0      0   1
  Germany FR    0           1      0   3
  Italy         0           0      0   4
  Spain         0           1      0   1
  Uruguay       0           0      0   2
  Sum           2           3      1  20
```

Le tableau des fréquences marginales montre le nombre total de victoires et de places de finaliste pour chaque pays sur l'ensemble du tableau de contingence. Par exemple, l'Argentine a un total de 2 victoires et places de finaliste, le Brésil en a 5, et ainsi de suite.

```r
conditional_distribution <- prop.table(table_contingency, margin = 1)
print("conditional distribution")
print(addmargins(conditional_distribution))
```

```
[1] "conditional distribution"

            Argentina    Brazil Czechoslovakia    France   Germany Germany FR
  Argentina  0.0000000 0.0000000      0.0000000 0.0000000 0.0000000  0.5000000
  Brazil     0.0000000 0.0000000      0.2000000 0.0000000 0.2000000  0.0000000
  England    0.0000000 0.0000000      0.0000000 0.0000000 0.0000000  1.0000000
  France     0.0000000 1.0000000      0.0000000 0.0000000 0.0000000  0.0000000
  Germany    1.0000000 0.0000000      0.0000000 0.0000000 0.0000000  0.0000000
  Germany FR 0.3333333 0.0000000      0.0000000 0.0000000 0.0000000  0.0000000
  Italy      0.0000000 0.0000000      0.2500000 0.2500000 0.0000000  0.2500000
  Spain      0.0000000 0.0000000      0.0000000 0.0000000 0.0000000  0.0000000
  Uruguay    0.5000000 0.5000000      0.0000000 0.0000000 0.0000000  0.0000000
  Sum        1.8333333 1.5000000      0.4500000 0.2500000 0.2000000  1.7500000

              Hungary     Italy Netherlands    Sweden       Sum
  Argentina  0.0000000 0.0000000   0.5000000 0.0000000 1.0000000
  Brazil     0.0000000 0.4000000   0.0000000 0.2000000 1.0000000
  England    0.0000000 0.0000000   0.0000000 0.0000000 1.0000000
  France     0.0000000 0.0000000   0.0000000 0.0000000 1.0000000
  Germany    0.0000000 0.0000000   0.0000000 0.0000000 1.0000000
  Germany FR 0.3333333 0.0000000   0.3333333 0.0000000 1.0000000
  Italy      0.2500000 0.0000000   0.0000000 0.0000000 1.0000000
  Spain      0.0000000 0.0000000   1.0000000 0.0000000 1.0000000
  Uruguay    0.0000000 0.0000000   0.0000000 0.0000000 1.0000000
  Sum        0.5833333 0.4000000   1.8333333 0.2000000 9.0000000
```

Ce tableau montre la répartition conditionnelle des résultats de la Coupe du Monde de la FIFA en fonction du vainqueur. Par exemple, lorsque l'Argentine a gagné, elle a eu une probabilité de 0,5 d'être également finaliste.

```
conditional_lprop <- lprop(table_contingency)
print("line proportions")
print(conditional_lprop)
```

```
[1] "line proportions"

             Argentina Brazil Czechoslovakia France Germany Germany FR Hungary
  Argentina    0.0       0.0    0.0            0.0    0.0    50.0        0.0
  Brazil       0.0       0.0   20.0            0.0   20.0     0.0        0.0
  England      0.0       0.0    0.0            0.0    0.0   100.0        0.0
  France       0.0     100.0    0.0            0.0    0.0     0.0        0.0
  Germany    100.0       0.0    0.0            0.0    0.0     0.0        0.0
  Germany FR  33.3       0.0    0.0            0.0    0.0     0.0       33.3
  Italy        0.0       0.0   25.0           25.0    0.0    25.0       25.0
  Spain        0.0       0.0    0.0            0.0    0.0     0.0        0.0
  Uruguay     50.0      50.0    0.0            0.0    0.0     0.0        0.0
  All         15.0      10.0   10.0            5.0    5.0    15.0       10.0

             Italy Netherlands Sweden Total
  Argentina    0.0  50.0         0.0  100.0
  Brazil      40.0   0.0        20.0  100.0
  England      0.0   0.0         0.0  100.0
  France       0.0   0.0         0.0  100.0
  Germany      0.0   0.0         0.0  100.0
  Germany FR   0.0  33.3         0.0  100.0
  Italy        0.0   0.0         0.0  100.0
  Spain        0.0 100.0         0.0  100.0
  Uruguay      0.0   0.0         0.0  100.0
  All         10.0  15.0         5.0  100.0
```

La table présente les proportions pour différents pays et attributs,elle permet de comprendre comment les différentes variables (pays, attributs) sont liées et distribuées dans la table de contingence.on peut voir que l'Argentine a 50% de la "ligne" totale, tandis que le Brésil a 20% de la "ligne" totale.

```
conditional_cprop <- cprop(table_contingency)
print("column proportions")
print(conditional_cprop)
```

```
[1] "column proportions"

             Argentina Brazil Czechoslovakia France Germany Germany FR Hungary
  Argentina    0.0       0.0    0.0            0.0    0.0    33.3        0.0
  Brazil       0.0       0.0   50.0            0.0  100.0     0.0        0.0
  England      0.0       0.0    0.0            0.0    0.0    33.3        0.0
  France       0.0      50.0    0.0            0.0    0.0     0.0        0.0
  Germany     33.3       0.0    0.0            0.0    0.0     0.0        0.0
  Germany FR  33.3       0.0    0.0            0.0    0.0     0.0       50.0
  Italy        0.0       0.0   50.0          100.0    0.0    33.3       50.0
  Spain        0.0       0.0    0.0            0.0    0.0     0.0        0.0
  Uruguay     33.3      50.0    0.0            0.0    0.0     0.0        0.0
  Total      100.0     100.0  100.0          100.0  100.0   100.0      100.0

             Italy Netherlands Sweden All
  Argentina    0.0  33.3         0.0   10.0
  Brazil     100.0   0.0       100.0   25.0
  England      0.0   0.0         0.0    5.0
  France       0.0   0.0         0.0    5.0
  Germany      0.0   0.0         0.0    5.0
  Germany FR   0.0  33.3         0.0   15.0
  Italy        0.0   0.0         0.0   20.0
  Spain        0.0  33.3         0.0    5.0
  Uruguay      0.0   0.0         0.0   10.0
  Total      100.0 100.0       100.0  100.0
```

cette analyse des proportions de colonne (column proportions) permet de mieux comprendre la répartition des observations entre les différents pays et attributs Les proportions de colonne indiquent la contribution relative de chaque pays au total pour chaque attribut. Par exemple, on peut voir que l'Argentine contribue pour 33,3% à l'attribut "Germany FR", tandis que le Brésil contribue pour 50% à l'attribut "Brazil".

```
theoretical_table <- chisq.test(table_contingency)
print(theoretical_table)
```

```
Warning message in chisq.test(table_contingency):
“Chi-squared approximation may be incorrect”

        Pearson's Chi-squared test

data:  table_contingency
X-squared = 62.444, df = 72, p-value = 0.7818
```

```
chi_squared_coefficient <- chisq.test(table_contingency)$statistic
print("chi_squared_coefficient")
print(chi_squared_coefficient)
```

```
Warning message in chisq.test(table_contingency):
“Chi-squared approximation may be incorrect”
[1] "chi_squared_coefficient"
X-squared
 62.44444
```

le résultat du test indique une p-value de 0,7818, bien supérieure au seuil de significativité classique de 0,05. Cela nous amène à ne pas rejeter l'hypothèse nulle d'indépendance entre les variables.Une valeur de 62.44444 est assez élevée, ce qui suggère potentiellement une relation significative

```
# Phi coefficient
phi_coefficient <- sqrt(chi_squared_coefficient / sum(table_contingency))
print("phi_coefficient")
print(phi_coefficient)
# T de Tshuprow
t_tshuprow <- chi_squared_coefficient / (nrow(fifa_wc) * (min(dim(table_contingency)) - 1))
print("t_tshuprow")
print(t_tshuprow)
# V de Cramer
n <- sum(table_contingency)
v_cramer <- sqrt(chi_squared_coefficient / (n * (min(dim(table_contingency)) - 1)))
print("v_cramer")
print(v_cramer)
```

```
[1] "phi_coefficient"
X-squared
 1.766981
[1] "t_tshuprow"
X-squared
0.3902778
[1] "v_cramer"
X-squared
0.6247222
```

1. Phi coefficient :Une valeur de 1.766981 indique une association positive et relativement forte entre les deux variables.
2. T de Tschuprow :Une valeur de 0.3902778 indique une association modérée à forte entre les deux variables.
3. V de Cramer :Une valeur de 0.6247222 indique une association relativement forte entre les deux variables.

```
correlation <- cor(fifa_wc$GoalsScored, fifa_wc$MatchesPlayed)
print("correlation")
print(round(correlation, 2))
```

```
[1] "correlation"
[1] 0.88
```

Une corrélation de 0.88 indique une relation linéaire forte et positive entre le nombre de matchs joués et le nombre de buts marqués par un joueur de football.

```
# Simple linear regression
regression_model <- lm(GoalsScored ~ MatchesPlayed, data = fifa_wc)
print("regression_model")
summary(regression_model)
```

```
[1] "regression_model"

Call:
lm(formula = GoalsScored ~ MatchesPlayed, data = fifa_wc)

Residuals:
    Min      1Q  Median      3Q     Max 
-21.064 -10.730  -5.702   6.221  47.560 

Coefficients:
              Estimate Std. Error t value Pr(>|t|)    
(Intercept)    48.8149     9.7982   4.982 9.65e-05 ***
MatchesPlayed   1.6779     0.2175   7.713 4.10e-07 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 16.33 on 18 degrees of freedom
Multiple R-squared:  0.7677,	Adjusted R-squared:  0.7548 
F-statistic:  59.5 on 1 and 18 DF,  p-value: 4.105e-07
```

1. Modèle de régression :Le modèle estime que le nombre de buts marqués (GoalsScored) est une fonction linéaire du nombre de matchs joués (MatchesPlayed).
2. Coefficients :L'ordonnée à l'origine (Intercept) est de 48.8149, ce qui signifie que le joueur marquerait en moyenne 48.81 buts même s'il n'avait joué aucun match.Le coefficient de pente pour MatchesPlayed est de 1.6779, ce qui signifie que pour chaque match supplémentaire joué, le joueur marquerait en moyenne 1.68 buts de plus.
3. Qualité du modèle :Le R-carré ajusté est de 0.7548, ce qui indique que le modèle explique environ 75% de la variance du nombre de buts marqués.La valeur-p du test F est inférieure à 0.05, ce qui signifie que le modèle est globalement significatif.
4. Significativité des coefficients :Les valeurs-p des coefficients sont inférieures à 0.05, indiquant que l'ordonnée à l'origine et le coefficient de pente sont statistiquement significatifs.

```r
fifa_wc$Attendance <- as.numeric(gsub("\\.", "", gsub(",", ".", fifa_wc$Attendance)))

correlation_attendance_goals <- cor(fifa_wc$Attendance, fifa_wc$GoalsScored)
print("correlation attendance goals")
print(round(correlation_attendance_goals, 2))
```

```
[1] "correlation attendance goals"
[1] 0.77
```

La valeur de corrélation de 0.77 indique une forte relation positive entre le nombre de spectateurs (Attendance) et le nombre de buts marqués (GoalsScored) dans les matchs de football.

```r
covariance <- cov(fifa_wc$GoalsScored, fifa_wc$MatchesPlayed)
print("covariance between 'GoalsScored' and 'MatchesPlayed'")
print(round(covariance, 2))
```

```
[1] "covariance between 'GoalsScored' and 'MatchesPlayed'"
[1] 497.46
```

La valeur de covariance calculée est 497.46, ce qui est une valeur positive. Cela signifie que les deux variables ont tendance à varier dans la même direction - lorsque l'une augmente, l'autre a également tendance à augmenter, et vice versa.

```r
partial_mean_variance <- aggregate(GoalsScored ~ Winner, data = fifa_wc, FUN = function(x) c(mean = mean(x), variance = var(x)))
print("Moyenne et variance partielles de'GoalsScored' grouped by 'Winner'")
print(partial_mean_variance)
```

```
[1] "Moyenne et variance partielles de'GoalsScored' grouped by 'Winner'"
      Winner GoalsScored.mean GoalsScored.variance
1  Argentina         117.0000             450.0000
2     Brazil         122.4000             928.8000
3    England          89.0000                   NA
4     France         171.0000                   NA
5    Germany         171.0000                   NA
6 Germany FR         117.3333             466.3333
7      Italy         111.7500            1642.9167
8      Spain         145.0000                   NA
9    Uruguay          79.0000             162.0000
```

Ce tableau permet de comprendre la performance moyenne des équipes gagnantes en termes de buts marqués,et aussi la consistance ou l'inconstance de cette performance lors de leurs victoires en Coupe du Monde.

```
fifa_wc$Winner <- as.factor(fifa_wc$Winner)
correlation_ratio <- aov(GoalsScored ~ Winner, data = fifa_wc)
print("correlation_ratio GoalsScored ~ Winner")
summary(correlation_ratio)
```

```
[1] "correlation_ratio GoalsScored ~ Winner"
            Df Sum Sq Mean Sq F value Pr(>F)
Winner       8  10468  1308.5   1.413  0.291
Residuals   11  10189   926.2
```

On conclue que les différences dans le nombre moyen de buts marqués entre les pays vainqueurs ne sont pas significativement différentes. Autrement dit, le nombre de buts marqués n’est pas fortement influencé par le fait qu’un pays en particulier ait gagné ou non.

- Visualisation:

```
winner_counts <- table(fifa_wc$Winner)
pie(winner_counts, main = "Pie chart \n Winners Distribution")
```

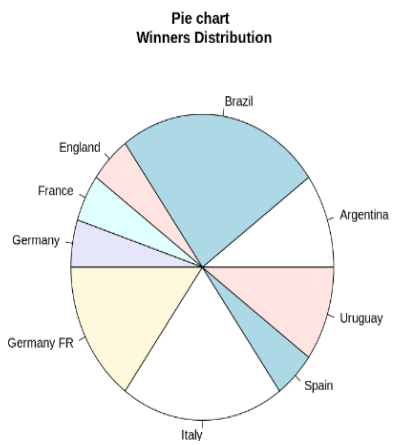


```
barplot(winner_counts, main = "Bar plot \n Winners", col = "blue", las = 2)
```

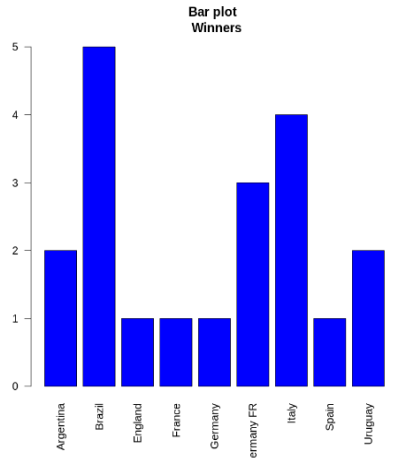

Le Pie chart montre une dominance historique du Brésil et de l'Allemagne dans les victoires de la Coupe du Monde, suivis par des équipes comme l'Italie. Les autres pays représentés (Argentine, Uruguay, Angleterre, France et Espagne) ont également gagné, mais moins souvent.
Le box plot montre que Brésil est le leader en termes de victoires, suivi par l'Allemagne et l'Italie. L'Argentine et l'Uruguay ont remporté la compétition plusieurs fois, tandis que l'Angleterre, la France et l'Espagne ont chacun une victoire unique. Ce graphique permet de visualiser facilement la répartition des victoires entre les différents pays et de voir la domination de certaines équipes au fil de l'histoire.

```
plot(fifa_wc$Year, fifa_wc$GoalsScored, type="h",
main="Buts marqués par édition", xlab="Année", ylab="Buts")
```

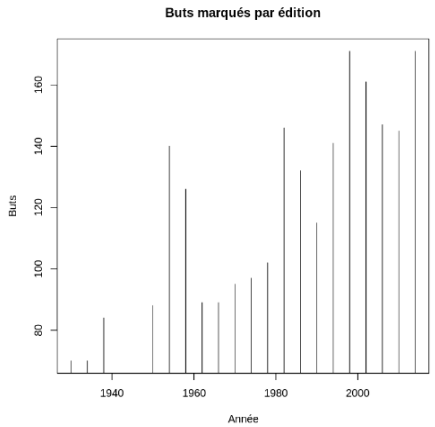

le graphique révèle une tendance globale d'augmentation des buts marqués par édition, avec des fluctuations historiques qui peuvent être attribuées à des changements dans le format du tournoi, le nombre d'équipes, et les stratégies de jeu.

```
plot(
  factor(fifa_wc$QualifiedTeams),main = "Bar plot \n Qualified Teams",
  xlab = "Équipes qualifiées",ylab = "Fréquence",col = "green"  )
```

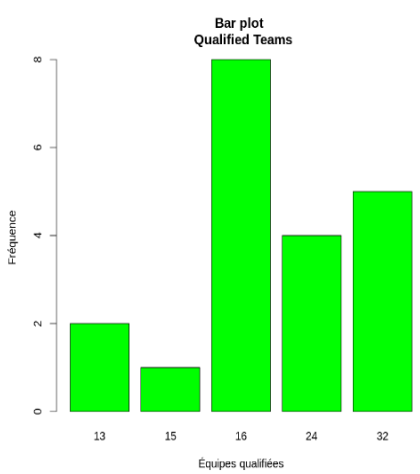


```
plot(ecdf(fifa_wc$QualifiedTeams),
main = "Cumulative plot \n QualifiedTeams",
 xlab = "Nombre d'équipes qualifiées", ylab = "CDF")
```

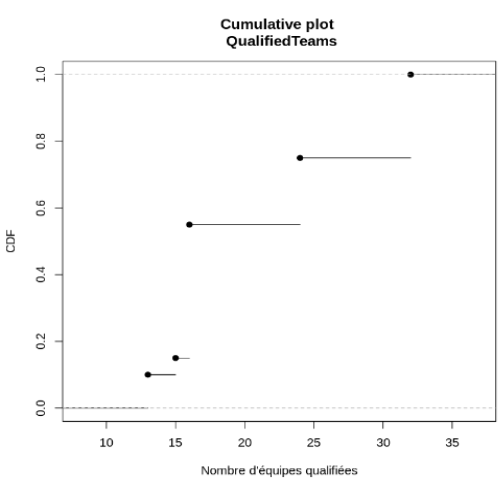

Le bar plot montre que le nombre d'équipes qualifiées a varié au fil des années, mais la configuration de 16 équipes qualifiées semble avoir été utilisée plus fréquemment, suivie de 32 équipes, ce qui pourrait indiquer une tendance historique dans les formats de la Coupe du Monde.

La CDF indique que le format de 16 équipes était le plus courant jusqu'à une certaine époque, après quoi le nombre d'équipes a augmenté pour atteindre 24, puis finalement 32. Cela montre une augmentation progressive de la participation dans le tournoi au fil des années.

```
boxplot(fifa_wc$GoalsScored, main = "Boxplot \n'GoalsScored",
 ylab = "Buts Marqués",col = "red")
extreme_values <- boxplot.stats(fifa_wc$GoalsScored)$out
extreme_indices <- which(fifa_wc$GoalsScored %in% extreme_values)
print(extreme_values)
print(extreme_indices)
```

```
integer(0)
integer(0)
```

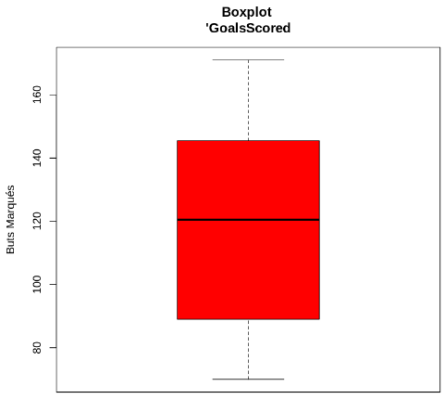


```
boxplot(fifa_wc$GoalsScored, fifa_wc$QualifiedTeams,
        fifa_wc$MatchesPlayed,
        names = c("Goals Scored", "Qualified Teams",
        "Matches Played"),
        main = "Boxplot for multiple quantitative variables",
        col="yellow")
```

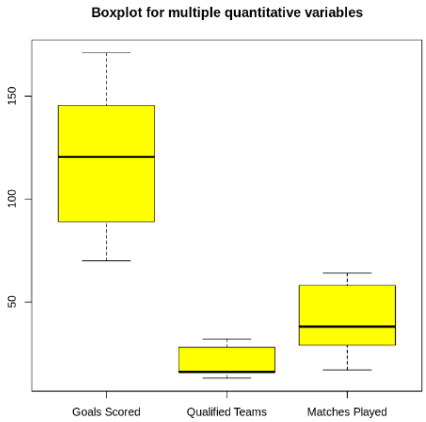

Le boxplot montre que les buts marqués sont relativement bien concentrés entre 100 et 140, avec une dispersion modérée et sans valeurs extrêmes. Cela pourrait indiquer une certaine régularité dans le nombre de buts marqués entre les différents tournois de la Coupe du Monde, sans variations drastiques.

```r
plot(fifa_wc$MatchesPlayed, fifa_wc$GoalsScored,
  main = "Goals Scored vs Matches Played",
     xlab = "Matches Played", ylab = "Goals Scored")
```

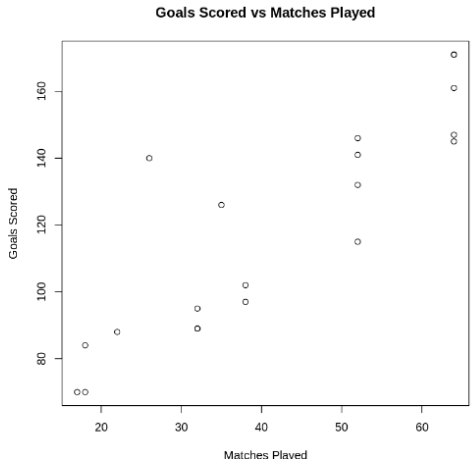


```r
model <- lm(GoalsScored ~ MatchesPlayed, data = fifa_wc)
plot(fifa_wc$MatchesPlayed, fifa_wc$GoalsScored,
main = "Régression: Goals Scored sur Matches Played",
     xlab = "Matches Played", ylab = "Goals Scored")
abline(model, col = "red")
```

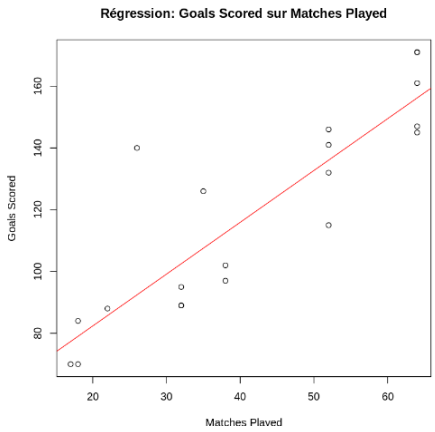

Le graphique suggère que les équipes ou les joueurs qui jouent plus de matchs marquent généralement plus de buts, bien qu'il existe une grande variabilité dans l'efficacité du score.
Ce modèle de régression suggère une tendance générale où le nombre de buts augmente avec le nombre de matchs joués, bien qu'il y ait une variabilité considérable autour de cette tendance.

```r
mosaicplot(table(fifa_wc$Country, fifa_wc$Winner),
main="Répartition des pays hôtes et gagnants",
lab="Pays hôtes", ylab="Pays gagnants",
col=rainbow(length(unique(fifa_wc$Winner))))
```

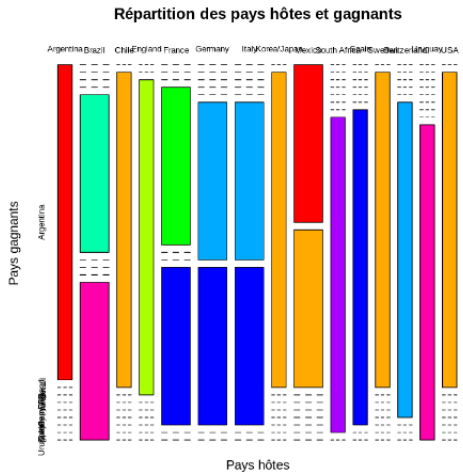

Ce diagramme mosaïque montre la relation entre les pays hôtes et gagnants, tout en soulignant les pays qui ont eu un rôle important à la fois en accueillant l'événement et en le remportant. Les tendances montrent que certains pays sont à la fois des hôtes fréquents et des vainqueurs réguliers.

```r
winner_counts <- data.frame(table(fifa_wc$Winner))
ggplot(winner_counts, aes(x = "", y = Freq, fill = Var1)) +
  geom_bar(stat = "identity", width = 1) +
  coord_polar("y") +
  labs(title = "Distribution des Gagnants de la Coupe du Monde") +
  theme_void()
```

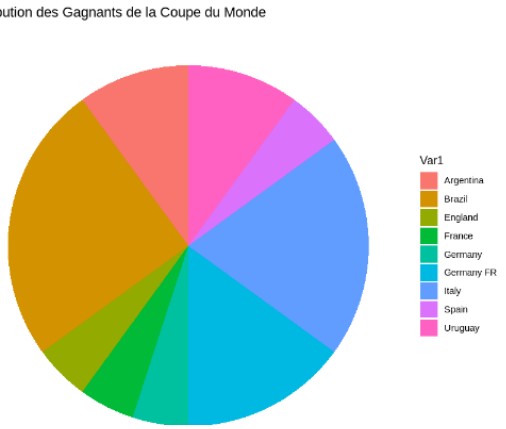

Ce diagramme circulaire montre la répartition des victoires de la Coupe du Monde par pays. La taille de chaque segment représente le nombre de victoires de chaque pays, permettant de visualiser rapidement les nations les plus dominantes. Par exemple, un segment plus grand pour le Brésil ou l'Allemagne indiquerait un plus grand nombre de victoires, tandis que des segments plus petits montrent des victoires moins fréquentes.

```r
pie(table(fifa_wc$Country), main="Répartition des pays hôtes")
```

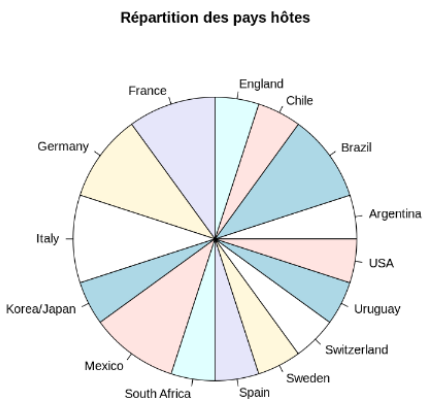

Le diagramme montre quels pays ont accueilli la Coupe du Monde et combien de fois. Les segments de taille similaire suggèrent que la plupart des pays n'ont accueilli le tournoi qu'une seule fois, sauf quelques exceptions qui ont accueilli plus fréquemment. Cela illustre une répartition géographique variée de l’accueil du tournoi.

```r
ggplot(winner_counts, aes(x = Var1, y = Freq, fill = Var1)) +
  geom_bar(stat = "identity") +
  labs(title = "Gagnants de la Coupe du Monde", x = "Gagnants", y = "Fréquence") +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```

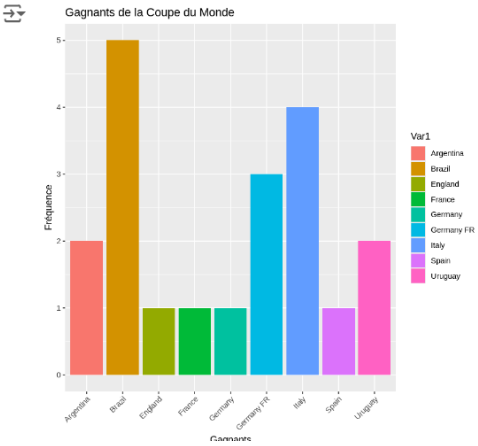

Le diagramme en barres illustre la fréquence des victoires en Coupe du Monde par pays. Le Brésil, l'Allemagne et l'Italie apparaissent comme les pays les plus victorieux, tandis que d'autres, comme l'Angleterre et l'Espagne, n'ont remporté qu'une seule fois.

```r
ggplot(fifa_wc, aes(x = QualifiedTeams)) +
  stat_ecdf(geom = "step") +
  labs(title = "Cumulatif Croissant des Équipes Qualifiées",
 x = "Nombre d'Équipes Qualifiées", y = "Cumulative Frequency")
```

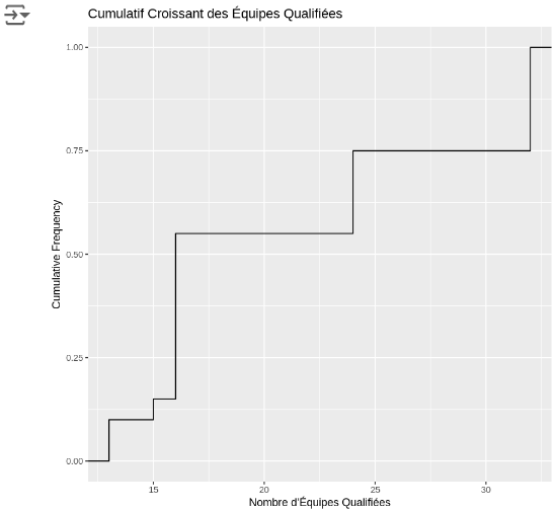

Le graphique en escalier indique la proportion cumulative d'éditions de la Coupe du Monde ayant un certain nombre d'équipes qualifiées ou moins. La ligne monte en fonction du nombre d'équipes qualifiées, indiquant la proportion croissante d'éditions de la Coupe du Monde qui atteignent ou dépassent un certain nombre d'équipes qualifiées.

```r
install.packages("gridExtra")
library(gridExtra)
p1 <- ggplot(fifa_wc, aes(x = GoalsScored)) + geom_histogram(binwidth = 10, fill = "blue", alpha = 0.7) +
  labs(title = "Histogramme GoalsScored")

p2 <- ggplot(fifa_wc, aes(x = QualifiedTeams)) + geom_histogram(binwidth = 1, fill = "green", alpha = 0.7) +
  labs(title = "Histogramme QualifiedTeams")

p3 <- ggplot(fifa_wc, aes(x = MatchesPlayed)) + geom_histogram(binwidth = 1, fill = "red", alpha = 0.7) +
  labs(title = "Histogramme MatchesPlayed")

grid.arrange(p1, p2, p3, nrow = 1)
```

```
Installing package into '/usr/local/lib/R/site-library'
(as 'lib' is unspecified)
```

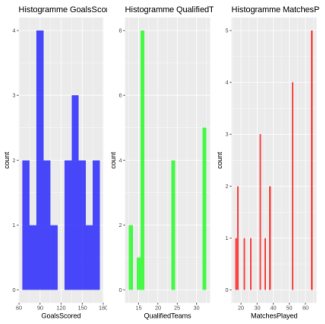

Ces trois histogrammes montrent comment certaines caractéristiques des éditions de la Coupe du Monde, comme les buts marqués, le nombre d'équipes qualifiées et le nombre de matchs joués, se sont distribuées historiquement.

```r
fifa_wc_xts <- xts(fifa_wc$GoalsScored, order.by = as.Date(paste(fifa_wc$Year, "01", "01", sep = "-")))
colnames(fifa_wc_xts) <- "GoalsScored"
candleChart(fifa_wc_xts, name = "Goals Scored Candlestick Chart", theme = chartTheme("white"))
```

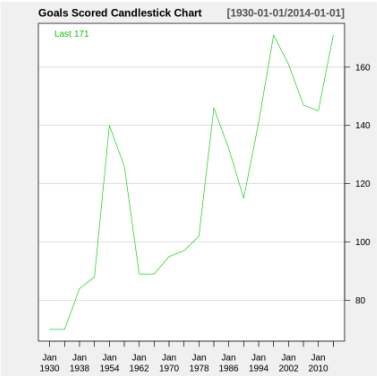

Ce graphique montre une évolution globale positive du nombre de buts marqués par édition de la Coupe du Monde, avec des variations attribuables à des changements structurels dans le tournoi ou des facteurs liés au jeu lui-même.

```r
ggplot(fifa_wc, aes(x = GoalsScored)) +
  geom_density(fill = "lightblue", alpha = 0.6) +
  ggtitle("Density Plot of Goals Scored") +
  xlab("Goals Scored") +
  ylab("Density") +
  theme_minimal()
```

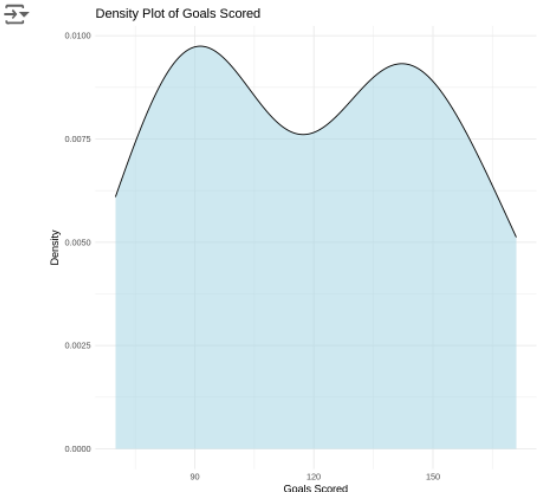

Ce graphique de densité révèle que le nombre de buts marqués dans les éditions de la Coupe du Monde a eu tendance à se regrouper autour de deux valeurs principales, suggérant peut-être des périodes distinctes dans le style de jeu ou des modifications dans le format du tournoi. La distribution bimodale peut refléter des changements historiques dans le nombre d'équipes, les règles ou la stratégie de jeu.

```r
third_place_counts <- table(fifa_wc$Third)
barplot(third_place_counts,
        main = "Frequency of Third Place by Country",
        xlab = "Country",
        ylab = "Number of Times in Third Place",
        col = "skyblue",
        las = 2,
        cex.names = 0.5)
```

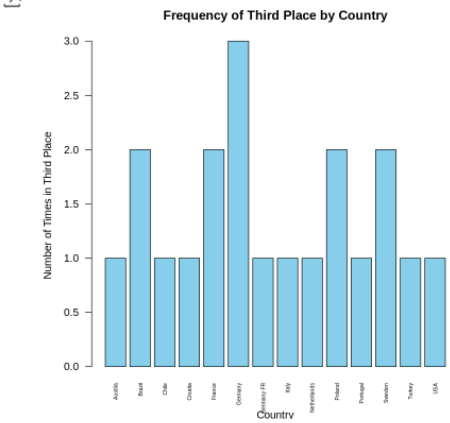

Ce diagramme en barres montre la capacité de certains pays à atteindre des performances élevées de manière régulière, en se plaçant plusieurs fois en troisième position. Cela peut indiquer des pays ayant une équipe compétitive mais qui n’ont pas encore remporté la Coupe ou sont arrivés fréquemment en demi-finale.

```r
bwplot(GoalsScored ~ Country, data=fifa_wc,
       main="Boxplot of Goals Scored by Team",
       xlab="Team", ylab="Goals Scored",
       scales = list(x = list(rot = 45, cex = 0.7)))
```

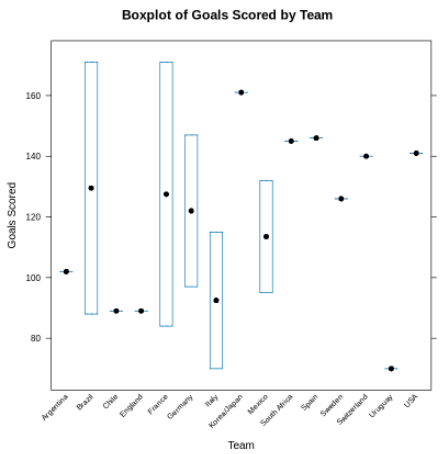

Ce boxplot met en évidence la variabilité des performances offensives des différentes équipes lors de la Coupe du Monde. Les équipes avec des boîtes plus étendues et des valeurs aberrantes (comme le Brésil et l'Allemagne) ont eu des performances fluctuantes avec des pics importants de buts marqués. Ce graphique permet ainsi de comparer l'efficacité offensive et la consistance des performances entre les équipes nationales au fil des éditions.

```r
barchart(QualifiedTeams ~ Year, data = worldcups,
         main = "Qualified Teams by Year",
         xlab = "Year",
         ylab = "Number of Qualified Teams",
         col = "lightgreen")
```

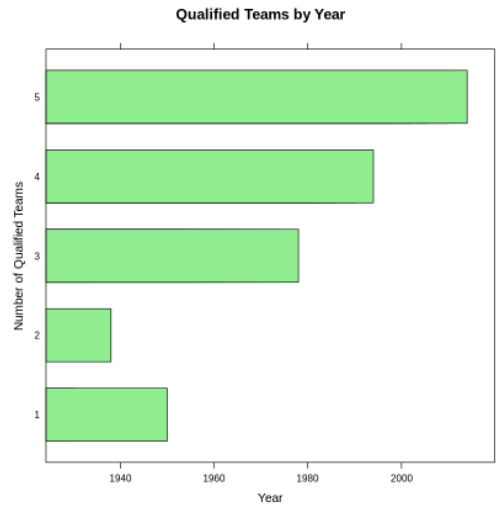

Ce diagramme en barres souligne l'expansion continue de la Coupe du Monde au fil des décennies, reflétant les changements structurels dans le nombre d'équipes qualifiées. Cette tendance indique l'élargissement de la portée mondiale de l'événement et l'intérêt accru pour intégrer un plus grand nombre de nations dans la compétition.

```
ggplot(worldcups, aes(x = Year, y = Attendance)) +
  geom_line(group = 1, colour = "blue") +
  geom_point(colour = "red") +
  labs(title = "Attendance at World Cups Over the Years",
       x = "Year",y = "Attendance") +
  theme_minimal()
```

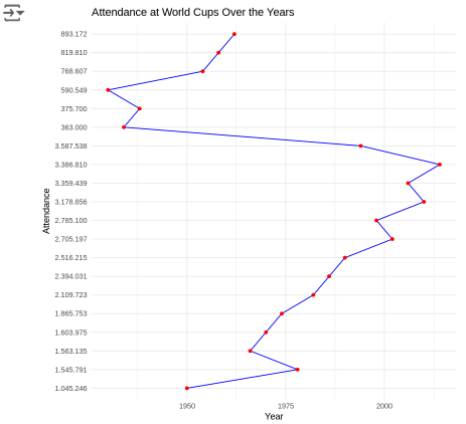

Ce graphique montre l'évolution de la popularité de la Coupe du Monde au fil des décennies, avec une croissance générale de l'assistance malgré quelques fluctuations. Les hausses peuvent être attribuées à des éditions populaires ou à des pays organisateurs dotés de grandes infrastructures, tandis que les baisses reflètent des éditions dans des contextes moins favorables. Ce graphique souligne l'importance croissante de la Coupe du Monde dans le monde du sport.

```
ggplot(qualified_count, aes(x = reorder(Country, -TotalQualified),
y = TotalQualified)) +
  geom_bar(stat = "identity", fill = "lightblue") +
  labs(title = "Countries with Most Qualifications for the World Cup",
       x = "Country",y = "Total Qualifications") +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```

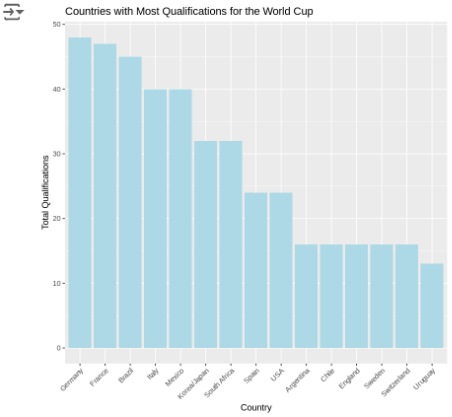


```
ggplot(qualified_count, aes(x = reorder(Country, TotalQualified), y = TotalQualified)) +
  geom_point(size = 3, aes(color = TotalQualified)) +
  geom_segment(aes(xend = Country, yend = 0), color = "grey80") +
  labs(title = "Countries with Most World Cup Qualifications",
       subtitle = "Total Qualifications per Country",
       x = "Country",y = "Total Qualifications") +
  scale_color_gradient(low = "lightblue", high = "darkblue") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1, size = 10),
        plot.title = element_text(size = 16, face = "bold"),
        plot.subtitle = element_text(size = 12, face = "italic"),
        legend.position = "none")
```

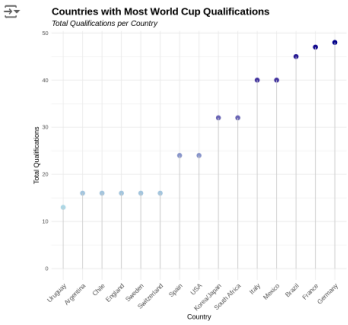

Ce graphique met en évidence les nations de football qui ont maintenu une performance élevée et constante pour se qualifier à plusieurs reprises pour la Coupe du Monde. Les pays en tête, comme le Brésil et l'Allemagne, illustrent leur position de leaders historiques dans le monde du football, tandis que la diversité des pays présents reflète l'expansion de l'intérêt pour la Coupe du Monde dans diverses régions du globe.

Ce graphique illustre l'histoire de la performance des équipes nationales en matière de qualifications à la Coupe d Monde. Les pays les plus qualifiés, comme le Brésil et l'Allemagne, apparaissent clairement en tête, montrant leur constance et leur place de leaders mondiaux. Le gradient de couleur facilite également l'identification des performances exceptionnelles et met en valeur la domination de certaines équipes sur les autres.

```r
winner_freq_df <- as.data.frame(table(worldcups$Winner))
colnames(winner_freq_df) <- c("Winner", "Freq")
p4 <- ggplot(winner_freq_df, aes(x = Winner, y = Freq, size = Freq)) +
  geom_point(color = "blue", alpha = 0.6) +
  labs(title = "Bubble Chart of Winners", x = "Winner", y = "Frequency") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
print(p4)
```

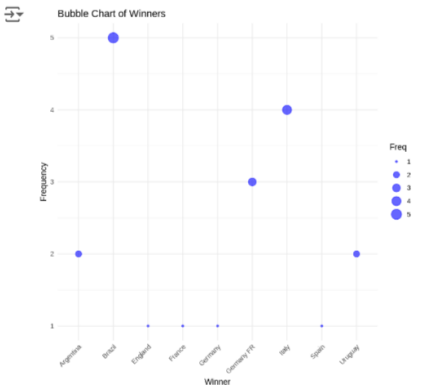


```r
winner_freq <- table(fifa_wc$Winner)
wordcloud(names(winner_freq), freq = winner_freq
min.freq = 1, colors = brewer.pal(8, "Dark2"))
```

Ce graphique met en évidence les pays les plus performants dans l'histoire de la Coupe du Monde, avec le Brésil en tête suivi de près par des équipes comme l'Allemagne et l'Italie. Les tailles et les positions des bulles permettent une visualisation claire de la domination de certains pays dans cette compétition prestigieuse.

Le nuage de mots et le graphique à barres donnent ensemble un aperçu complet des performances des pays dans la Coupe du Monde. Le nuage de mots met l'accent sur les champions les plus fréquents, tandis que le graphique à barres facetté montre les différentes positions ou résultats atteints par ces pays dans la compétition, offrant une perspective plus nuancée sur leur parcours.

```r
barchart(Frequency ~ Country | type,
         data = combined_df,
         main = "faceted bar plots-World Cup Outcomes",
         ylab = "Number of Occurrences",
         layout = c(1, 2),col = c("skyblue", "salmon"),
         scales = list(x = list(rot = 90, cex = 0.8)),
         auto.key = list(columns = 2))
```

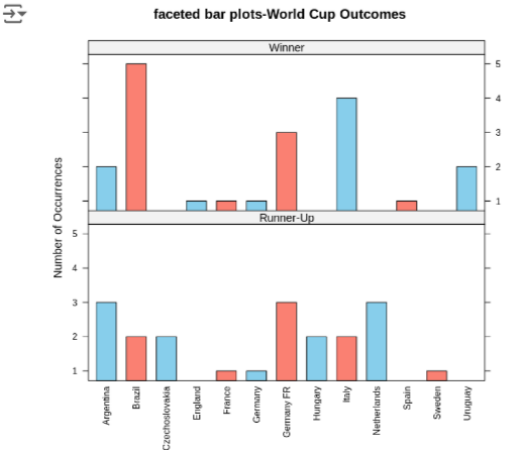

La première facette, "Winner", indique le nombre de fois qu'un pays a remporté la Coupe du Monde. La deuxième facette, "Runner-Up", montre le nombre de fois qu'un pays est arrivé en deuxième position.Certains pays comme le Brésil et l'Allemagne se démarquent avec un nombre élevé de victoires ("Winner").

D'autres pays, comme les Pays-Bas, apparaissent souvent dans la catégorie "Runner-Up", indiquant qu'ils ont atteint la finale plusieurs fois sans forcément gagner.

```r
winner_count <- as.data.frame(table(fifa_wc$Winner))
treemap(winner_count,
        index = "Var1",
        vSize = "Freq",
        title = "Treemap of World Cup Winners",
        palette = "Set3")
```

Ce treemap offre une visualisation claire et rapide des pays les plus victorieux en Coupe du Monde. Il met en évidence la domination du Brésil, ainsi que le succès de l'Allemagne et de l'Italie dans l'histoire de la compétition.

3. Etude avec Python sur la dataset “WorldCupMatches.csv”

Préparation des données:

Aperçu général du jeu de données:

```python
print("Info générales sur le DataFrame:")
df.info()
```

```
Info générales sur le DataFrame:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 37784 entries, 0 to 37783
Data columns (total 11 columns):
 #   Column         Non-Null Count  Dtype
---  ------         --------------  -----
 0   RoundID        37784 non-null  int64
 1   MatchID        37784 non-null  int64
 2   Team Initials  37784 non-null  object
 3   Coach Name     37784 non-null  object
 4   Line-up        37784 non-null  object
 5   Shirt Number   37784 non-null  int64
 6   Player Name    37784 non-null  object
 7   Position       4143 non-null   object
 8   Event          9069 non-null   object
 9   Event_Minute   9069 non-null   float64
 10  Event_Type     9069 non-null   object
dtypes: float64(1), int64(3), object(7)
memory usage: 3.2+ MB
```

Ce DataFrame contient des données structurées relatives aux matchs d'un tournoi, permettant une analyse approfondie des performances des équipes et des joueurs à travers plusieurs dimensions. Les colonnes suivantes sont utilisées pour décrire et organiser les événements du tournoi:

RoundID :
Cette colonne identifie la phase du tournoi dans laquelle chaque match a eu lieu, telle que la phase de groupes, les huitièmes de finale, ou les quarts de finale.

MatchID :
Chaque match du tournoi est associé à un identifiant unique, permettant de lier les statistiques et les événements spécifiques à un match particulier.

Team Initials :
Cette colonne contient l'abréviation du nom de l'équipe, permettant une identification rapide des équipes participantes.

Coach Name :
Cette colonne indique le nom de l'entraîneur, suivi du code pays entre parenthèses. Elle est pertinente pour les analyses relatives à l'impact des entraîneurs sur les performances des équipes.

Line-up :
Cette colonne est essentielle pour différencier les joueurs titulaires de ceux qui figurent en tant que remplaçants. Cette distinction a un impact significatif sur l'analyse de la dynamique de jeu, permettant d'évaluer les performances respectives des joueurs en fonction de leur rôle au sein de l'équipe.

Shirt Number :
Le numéro de maillot attribué à chaque joueur pendant le match.

Player Name :
Cette colonne contient le nom du joueur ayant participé au match.

Position :
Indique la position du joueur sur le terrain. Cette information est essentielle pour analyser l'influence des différents rôles sur la performance des équipes, en tenant compte des spécificités liées à chaque poste, qu'il s'agisse des attaquants, des milieux de terrain ou des défenseurs.

Event_Minute :
Cette colonne indique la minute précise du match où l'événement a eu lieu. Cela permet de situer l'action dans le temps, facilitant ainsi les analyses temporelles des événements et leur impact sur le flux du match.

Event_Type :
Cette colonne catégorise le type d'événement. Elle permet de regrouper et d'analyser les événements de manière structurée, en facilitant l'étude des différents types d'actions (buts, passes, fautes, etc.) et leur fréquence au cours du match.

Prétraitement et nettoyage des données:

Analyse des valeurs manquantes pour chaque variable:

```
[ ] plt.figure(figsize=(10,8))
    msno.bar(df,color='lightblue')
    plt.title("Checking for Null Values\n")
    plt.show()
```

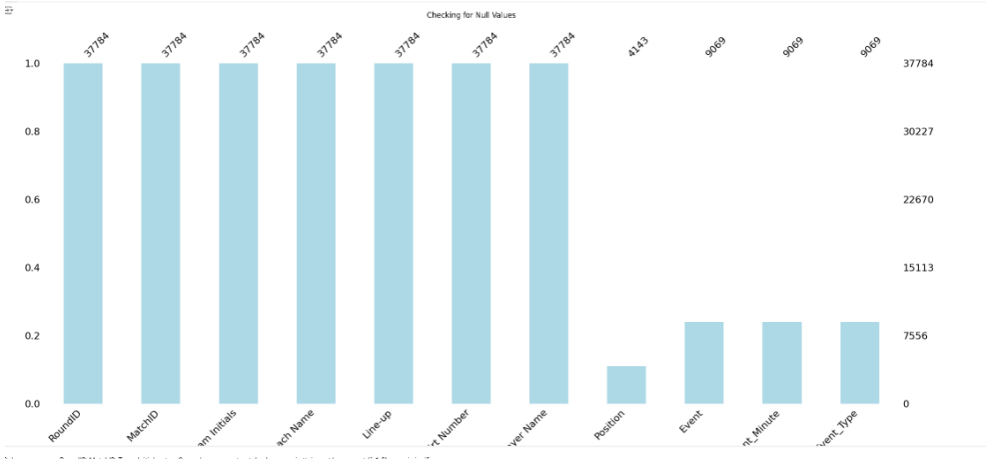

Les colonnes **RoundID**, **MatchID**, **Team Initials**, entre autres, ne présentent aucune valeur manquante, indiquant que chaque ligne du jeu de données contient une valeur valide pour ces attributs. Cela signifie qu'elles atteignent une complétude maximale (1.0), ce qui en fait des variables entièrement renseignées dans l'ensemble des données. En revanche, la colonne **Position** ne comporte que 4143 valeurs valides, signalant une couverture partielle et laissant présumer des valeurs manquantes pour une proportion significative des entrées. De même, la colonne **Event** contient environ 7556 valeurs valides, ce qui indique également la présence de valeurs manquantes pour une partie des observations.

Imputation des Valeurs Manquantes:

1.Pour les données quantitative:

```
[ ] cols=df.select_dtypes(include=['int64','float64']).columns
    for col in cols:
      df[col].fillna(df[col].mean())
```

Afin de préserver la qualité et la cohérence des données pour les analyses ultérieures, les valeurs manquantes dans les colonnes numériques ont été remplacées par la moyenne de chaque colonne concernée. Cette méthode réduit les risques de distorsion statistique et garantit la complétude de chaque observation. Ainsi, cette imputation optimise la fiabilité des résultats dans les modèles de machine learning en minimisant l'impact des données absentes.

2.Pour les données qualitative:

```
[ ] cols=df.select_dtypes(include='object').columns
    for col in cols:
      df[col].fillna(df[col].mode()[0])
```

Pour chaque colonne catégorielle contenant des valeurs manquantes, nous avons imputé ces dernières en utilisant la modalité la plus fréquente. Cette approche permet de maintenir les distributions de fréquence d'origine tout en minimisant l'impact des données manquantes, améliorant ainsi la qualité et la robustesse des analyses.

Traitement des doublons :

```
[ ]  df = df.drop_duplicates()
```

En supprimant les entrées dupliquées, nous assurons l'unicité de chaque observation, réduisant ainsi le risque de biais dans les analyses statistiques. Cette démarche optimise l'intégrité des données et garantit des résultats plus fiables.

Correction des erreurs de saisie :

```
[ ]  cols=df.select_dtypes(include=['object']).columns
     for col in cols:
        df[col] = df[col].str.lower()
```

En appliquant cette transformation, nous assurons la cohérence des valeurs textuelles, facilitant ainsi la comparaison et le regroupement des données sans impact des différences de casse. Cette standardisation améliore la qualité et renforce la fiabilité des analyses.

Analyse unidimensionnelle:

Statistiques Descriptives:

Données quantitatives:

```
print("Statistiques descriptives du DataFrame :")
df_copy.describe()
```

```
Statistiques descriptives du DataFrame :
```

	Shirt Number	Event_Minute
count	37784.000000	9069.000000
mean	10.726022	58.048407
std	6.960138	24.056693
min	0.000000	1.000000
25%	5.000000	45.000000
50%	11.000000	63.000000
75%	17.000000	76.000000
max	23.000000	120.000000

Description statistique des numéros de maillot :

La moyenne des numéros de maillot est de 10,73, ce qui indique une tendance générale vers des numéros proches de 10, une valeur fréquemment observée dans les équipes sportives. Cette valeur suggère une concentration des numéros en dessous de 20, avec quelques numéros plus élevés qui augmentent légèrement la moyenne. La médiane est de 11, ce qui signifie que 50 % des joueurs portent un numéro inférieur ou égal à 11. Cela est représentatif des pratiques courantes où les numéros 1 à 11 sont souvent attribués aux titulaires ou aux joueurs occupant des positions clés, comme c'est le cas dans des sports tels que le football.

Le premier quartile (Q1) est de 5,0, ce qui montre que 25 % des joueurs portent un numéro inférieur ou égal à 5, généralement associé aux joueurs occupant des postes défensifs. Le troisième quartile (Q3) est de 17,0, indiquant que 75 % des joueurs portent un numéro inférieur ou égal à 17, ce qui reflète une majorité de joueurs avec des numéros de maillot situés entre 1 et 17, en ligne avec les pratiques habituelles des sports d'équipe. Les numéros supérieurs à 17 sont moins fréquents, et peuvent correspondre à des remplaçants ou à des rôles spécifiques au sein de l'équipe.

Description statistique des minutes d'événements :

La moyenne des minutes d'événements est de 58,05 minutes, ce qui suggère que la majorité des événements se produisent autour de la 58e minute, un moment qui coïncide souvent avec le début de la deuxième mi-temps dans des matchs de football. Cette tendance peut refléter un pic d'intensité après la mi-temps, où les ajustements stratégiques et l'énergie des joueurs influencent les actions du jeu. La médiane, légèrement plus élevée à 63 minutes, indique que plus de la moitié des événements se produisent après la mi-temps, renforçant l'idée que la deuxième mi-temps est généralement plus dynamique et compétitive.

Le premier quartile (Q1) se situe à 45 minutes, ce qui montre que 25 % des événements ont lieu avant la fin de la première mi-temps, un moment où les ajustements tactiques n'ont pas encore été pleinement intégrés et avant que l'intensité ne croisse en seconde période. Le troisième quartile (Q3) est de 76 minutes, signifiant que 75 % des événements se produisent avant la 76e minute. Cela suggère que la majorité des événements ont lieu avant les toutes dernières minutes d'un match, bien que des actions notables puissent encore survenir en fin de match ou pendant les prolongations.

En termes de distribution, celle-ci semble légèrement asymétrique, avec une moyenne inférieure à la médiane, ce qui laisse entendre que certains événements surviennent tard dans le match, jusqu'à 120 minutes, notamment lors des prolongations. En résumé, bien que la majorité des événements se produisent autour de la 58e minute, la distribution reste équilibrée, avec des événements répartis tout au long des deux mi-temps et quelques-uns qui se prolongent dans les minutes supplémentaires.

Données qualitatives:

```
cols=df_copy.select_dtypes(include='object').columns
plotnumber=1
for i in range(len(cols)):
  if plotnumber<=len(cols):
    top_values=df_copy[cols[i]].value_counts().nlargest(10).index
    df_top=df_copy[df_copy[cols[i]].isin(top_values)]
    frequence_absolue=df_top[cols[i]].value_counts()
    frequence_relative=df_top[cols[i]].value_counts(normalize=True)*100
    mode=df_top[cols[i]].mode()
    print(f"\nle mode de {cols[i]} :\n {mode[0]}")
    print(f"\nFréquence absolue de {cols[i]} :\n {frequence_absolue}")
    print(f"\nFréquence relative de {cols[i]} :\n {frequence_relative}")
  plotnumber+=1
```

RoundID : Les valeurs les plus fréquentes pour la variable RoundID sont 255931 et 43950100, chacune apparaissant 2 208 fois, ce qui indique que ces étapes ou tours sont particulièrement représentés dans le dataset. En revanche, certains RoundID comme 462, 429, 418, 405, et 97410600 n'apparaissent pas du tout, signalant leur absence dans les données. Ces valeurs fréquentes représentent environ 11,96 % de l'ensemble des données, mettant en évidence une dominance de certains identifiants de tours dans la distribution.

MatchID : Les matchs identifiés par les MatchID 300186460, 300186462, et 300186474, avec 92 occurrences chacun, sont sur-représentés, ce qui pourrait refléter une structure particulière de collecte des données ou une répétition de certains matchs dans le dataset. Ces matchs représentent environ 10 % de l'ensemble des matchs, suggérant un biais vers certains matchs spécifiques.

Team Initials : L'équipe du Brésil (BRA) est la plus fréquemment mentionnée, avec 2 403 occurrences, suivie de l'Italie (ITA) et de l'Argentine (ARG), ce qui souligne leur rôle central dans le

dataset. Le Brésil représente environ 16 % des occurrences, confirmant son statut prédominant, tandis que l'Italie et l'Argentine suivent avec environ 12 %, indiquant une concentration autour de ces équipes historiques.

Coach Name : Luiz Felipe Scolari, l'entraîneur du Brésil, est mentionné 575 fois, suivi de Helmut Schön de l'Allemagne de l'Ouest. Cette prévalence reflète la longévité ou l'importance de ces entraîneurs dans le contexte du dataset. Scolari représente environ 12,78 % des mentions d'entraîneurs, signalant une concentration autour de certaines figures clés du football.

Line-up : Les compositions "N" et "S" sont presque équivalentes, avec "N" apparaissant 19 040 fois et "S" 18 744 fois. Cette quasi-parité suggère un équilibre entre les formations de départ dans les données. "N" occupe 50,39 % et "S" 49,61 %, ce qui montre que les deux compositions sont réparties presque également dans le dataset.

Player Name : Les joueurs les plus fréquemment mentionnés sont Ronaldo (33 occurrences) et Miroslav Klose (32 occurrences), deux figures emblématiques du football. Ronaldo représente environ 12,09 % des mentions de joueurs, et Klose suit de près à 11,72 %, indiquant leur rôle majeur dans les événements capturés par les données.

Position : Les gardiens de but (GK) sont les joueurs les plus fréquemment enregistrés avec 2 441 occurrences, suivis des centres (C). Cette sur-représentation des gardiens pourrait refléter une fréquence plus élevée d'événements impliquant cette position spécifique. Les gardiens de but représentent environ 59 % des postes, ce qui suggère que les événements impliquant les gardiens sont plus fréquents ou plus significatifs dans le contexte des données.

Event : Les événements "OH46'" (247 occurrences) et "IH46'" (206 occurrences) sont les plus fréquents, ce qui suggère que ces événements ont lieu à des moments clés du match. Ces événements représentent respectivement 23,11 % et 19,27 % de l'ensemble des événements, soulignant leur importance et leur récurrence dans les données.

Analyse des variables qualitatives :

Diagramme en bâtons:

```
[ ]  cols=df_copy.select_dtypes(include=['object']).columns
     plotnumber=1
     plt.figure(figsize=(20,25))
     for i in range(len(cols)):
       if plotnumber <= len(cols):
         ax=plt.subplot(3,3,plotnumber)
         top_values = df_copy[cols[i]].value_counts().nlargest(10).index
         df_top = df_copy[df_copy[cols[i]].isin(top_values)]
         sns.countplot(x=cols[i],data=df_top,ax=ax,palette='rocket')
         plt.title(f"\n{cols[i]} Value Counts\n")
         ax.set_xticklabels(ax.get_xticklabels(), rotation=90)
       plotnumber+=1
     plt.tight_layout()
     plt.show()
```

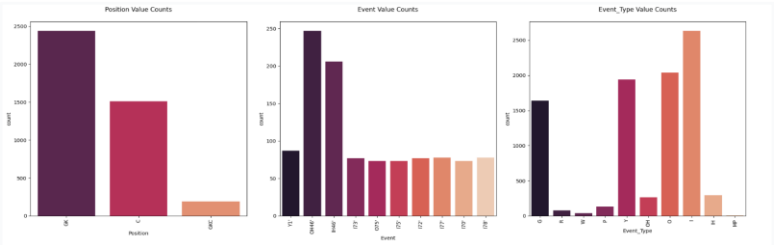

Initiales des équipes : Le graphique montre une forte prédominance de certaines équipes, avec une équipe atteignant près de 2500 occurrences. Cela peut refléter une couverture médiatique accrue ou une représentation plus fréquente de certaines équipes, possiblement en raison de leur succès, leur popularité, ou leur participation régulière à des compétitions majeures. Ces équipes sont probablement les plus connues ou les plus suivies dans le contexte des matchs représentés.

Noms des entraîneurs : Un entraîneur atteint presque 600 occurrences, ce qui suggère une figure marquante dans le dataset. Cette concentration pourrait être due à un entraîneur ayant une carrière longue, des succès notables, ou ayant encadré plusieurs équipes dans des compétitions importantes. Leur fréquence élevée dans les données peut également signaler leur rôle stratégique et leur influence dans les compétitions couvertes par le dataset.

Compositions d'équipe (Line-up) : La répartition entre 'S' (les titulaires) et 'N' (les remplaçants) est presque équivalente, avec environ 18 000 entrées pour chaque catégorie. Ce ratio de 50/50 suggère que les données couvrent un large éventail de joueurs, avec des ajustements tactiques fréquents basés sur les adversaires, les conditions de jeu, ou l'alternance dans les alignements. Cela pourrait aussi signifier que le dataset cherche à donner une vision complète des choix d'alignements sur le terrain.

Noms des joueurs : Des joueurs comme "CAFU" et "RONALDO" apparaissent plus de 30 fois chacun, ce qui suggère qu'ils sont des figures emblématiques du sport, souvent sélectionnées ou ayant marqué les matchs de manière significative. Leur fréquence élevée dans le dataset peut également refléter leur popularité auprès des fans et des analystes, ainsi que leur rôle clé dans les compétitions suivies.

Positions des joueurs : Les gardiens de but ("GK") sont largement représentés, suivis des milieux ou défenseurs centraux ("C"). Cette prédominance des gardiens pourrait être liée à une sur-représentation des actions impliquant cette position. Cela peut aussi être le reflet d'une stratégie de jeu où les gardiens jouent un rôle plus actif ou central, et donc plus visible dans les événements capturés.

Événements : Les événements comme "Y" et "G" sont les plus fréquents, avec plus de 200 occurrences chacun. L'événement "Y" fait référence à un **carton jaune** attribué à un joueur, tandis que "G" semble indiquer un **but marqué**. Cela montre que certains types d'événements, tels que les avertissements (cartons jaunes) et les buts à des moments clés, sont plus représentés dans le dataset. Cette fréquence élevée suggère qu'ils sont jugés particulièrement importants pour l'analyse des matchs, soulignant leur rôle central dans l'évolution du jeu. Ces événements peuvent être cruciaux dans la dynamique d'un match, car un carton jaune peut modifier le comportement d'un joueur ou d'une équipe, tandis qu'un but à un moment stratégique peut avoir un impact significatif sur le résultat final du match.

Diagramme circulaire:

```
cols=df_copy.select_dtypes(include=['object']).columns
plotnumber=1
for i in range(len(cols)):
  if plotnumber<=len(cols):
    top_values=df_copy[cols[i]].value_counts().nlargest(10).index
    df_top=df_copy[cols[i]].isin(top_values)
    col_count=df_copy[cols[i]][df_top].value_counts()
    fig=px.pie(values=col_count,names=col_count.index,color_discrete_sequence = px.colors.sequential.matter_r, width =800, height = 600, hole=0.5)
    fig.update_traces(textinfo='percent+label')
    fig.update_layout(title_text=f'{cols[i]} Value Counts')
    fig.show()

  plotnumber+=1
```

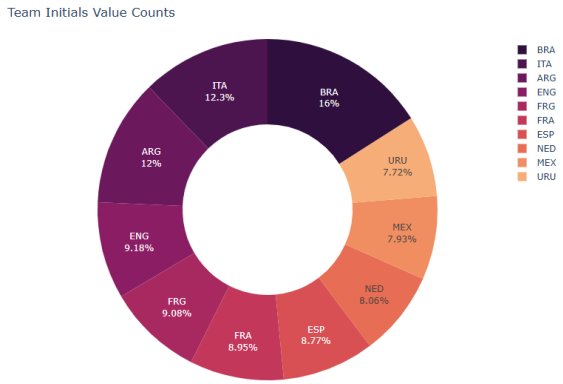

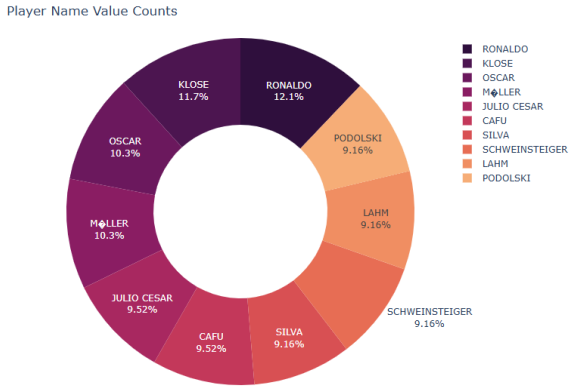

L'objectif est de **visualiser la distribution des valeurs les plus fréquentes** dans les colonnes de type objet de la DataFrame. Pour chaque colonne, un graphique en anneau est généré pour montrer les **10 valeurs les plus courantes** et leur **répartition en pourcentage**. Cela permet de mieux comprendre la concentration des valeurs dans ces colonnes catégorielles, ce qui peut être utile pour identifier des biais, des tendances, ou des valeurs dominantes dans le dataset.

Distribution marginale:

```
dist_marg_position=df['Position'].value_counts().reset_index()
dist_marg_position.columns=['Position','Count']
fig=go.Figure(data=[go.Table(
    header=dict(values=dist_marg_position.columns,fill_color='paleturquoise',align='center'),
    cells=dict(values=[dist_marg_position['Position'],dist_marg_position['Count']],fill_color='lavender',
               align='center')
)])
fig.show()
```

Position	Count
GK	2441
C	1510
GKC	192

La distribution marginale de la colonne `Position`, autrement dit le nombre d'occurrences de chaque type de position dans l'ensemble de données:

Position `GK` (Gardien de But) : Ce rôle est très fréquent avec **2 441** occurrences, ce qui signifie que les gardiens de but constituent la majorité des enregistrements. Cela pourrait indiquer que cette base de données contient plus de données ou de statistiques sur les gardiens.

Position `C` (Centre) : Avec **1 510** occurrences, cette position est également bien représentée, mais moins que `GK`. Cette répartition montre que les joueurs de cette position sont aussi importants dans l'analyse, mais en nombre inférieur.

Position `GKC` : Cette position est rare, avec seulement **192** occurrences.**GKC** représente un joueur qui a à la fois des responsabilités de **gardien de but** et de **joueur de centre**. Cela signifie que ce poste est hybride, combinant des fonctions défensives typiques d'un gardien avec des tâches plus offensives ou de distribution typiques d'un joueur de centre.

Analyse des variables quantitatives :

Analyse de la Dispersion et de la Répartition des Données:

```
cols=df_copy.select_dtypes(include=['int64','float64']).columns
plotnumber=1
for i in range(len(cols)):
  if plotnumber<=len(cols):
    fig=px.box(data_frame=df,x=cols[i],template = 'plotly_dark')
    fig.update_layout(title=f'Boîte à moustaches de la répartition de {cols[i]}')
    fig.show()
  plotnumber+=1
```

L'utilisation de Plotly Express pour la génération de la boîte à moustaches est justifiée par ses avantages interactifs et sa simplicité d'utilisation. Plotly Express permet de créer des visualisations de haute qualité avec peu de lignes de code, facilitant ainsi l'exploration et l'analyse des distributions de données. L'aspect interactif de Plotly, comme le zoom, le survol et l'affichage de valeurs détaillées, permet une meilleure compréhension des caractéristiques des données, telles que les valeurs aberrantes et les quartiles. Ces fonctionnalités rendent l'analyse plus intuitive et dynamique, ce qui est particulièrement utile pour des explorations approfondies des données.

Variable Shirt Number:

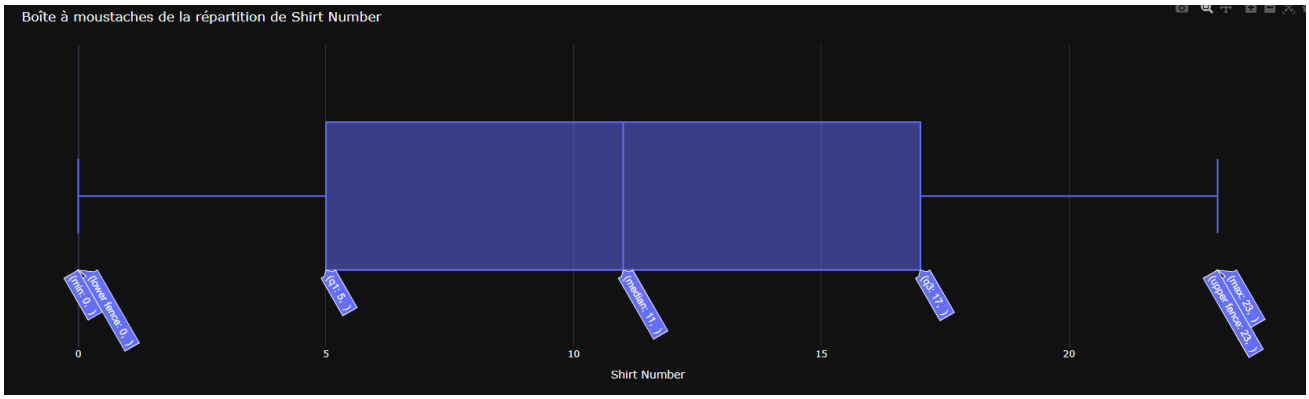

La visualisation de la boîte à moustaches pour la variable "shirt number" révèle que la médiane (7) est relativement proche du premier quartile (Q1) qui est 5. Cependant, on observe une large variation jusqu'au troisième quartile (Q3), situé à 17. Cette dispersion indique une certaine asymétrie dans la distribution des données, où les valeurs plus élevées semblent plus étendues et moins concentrées, suggérant que les numéros de maillots plus élevés sont plus diversifiés. Ce comportement est également visible à travers les moustaches, qui s'étendent davantage vers la partie supérieure, mettant en évidence des valeurs plus extrêmes dans la distribution.

Variable Event-Minute:

La visualisation de la boîte à moustaches pour la variable "event-minute" montre que la médiane est située à 63, avec une plage interquartile (de Q1 à Q3) relativement large, allant de 45 à 76. Cela indique une bonne dispersion des valeurs autour de la médiane, suggérant une répartition équilibrée des événements dans cette plage de temps. Les valeurs s'étendent de 1 à 120, ce qui

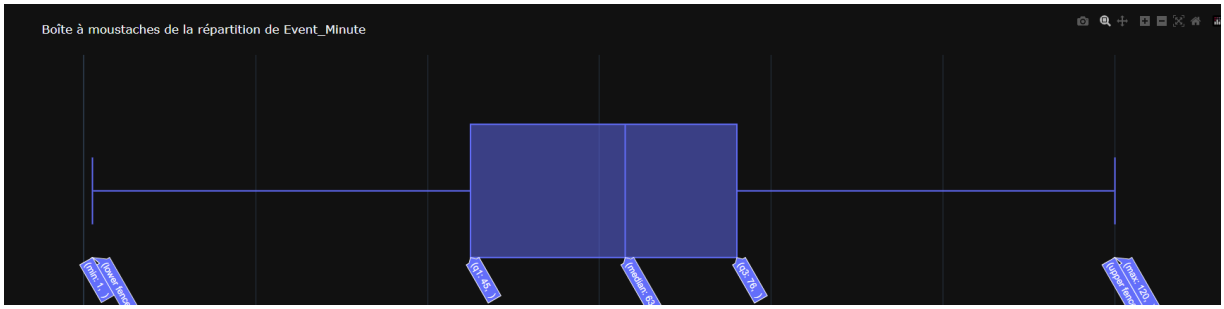

révèle que certains événements se produisent à des moments extrêmes, tant en début qu'en fin de période, illustrant une diversité dans la répartition temporelle des événements.

Évaluation de la symétrie et de l'aplatissement:

```
cols=df_copy.select_dtypes(include=['int64','float64']).columns
for i in range(len(cols)):
  skewness=df[cols[i]].skew()
  print(f"Asymétrie de {cols[i]}: {skewness}")
  kurtosis=df[cols[i]].kurt()
  print(f"Kurtosis de {cols[i]}: {kurtosis}")
```

Variable Shirt Number:

Asymétrie du numéro de maillot : 0,0321

La valeur de l'asymétrie étant proche de zéro, elle indique que la distribution des numéros de maillot est pratiquement symétrique. Cela signifie que les numéros sont répartis de manière relativement uniforme autour de la moyenne, sans tendance marquée vers des valeurs supérieures ou inférieures.

Kurtosis du numéro de maillot : -1,2267:

La kurtosis négative, inférieure à zéro, suggère que la distribution des numéros de maillot est de type *platykurtique*, c'est-à-dire plus aplatie que la distribution normale. Cela implique une concentration moins importante autour de la moyenne, avec une dispersion plus uniforme des valeurs et une présence réduite de valeurs extrêmes.

Variable Event-Minute:

Asymétrie des minutes d'événements : -0,5334:

L’asymétrie négative indique une légère déviation vers la gauche de la distribution des minutes d’événements, suggérant une tendance à ce que les événements se produisent légèrement plus tôt dans le déroulement des matchs.

Kurtosis des minutes d'événements : -0,2830:

La kurtosis légèrement négative indique une distribution modérément aplatie, caractérisée par une faible présence de valeurs extrêmes. Cela suggère une répartition relativement homogène des

minutes d'événements tout au long des matchs, sans forte concentration autour de la moyenne ni pics marqués.

Visualisation de la Symétrie et de l'Aplatissement de la Distribution avec Distplot:

```
[ ] cols=df_copy.select_dtypes(include=['int64','float64']).columns
    for i in range(len(cols)):
      plt.figure(figsize=(10,8))
      sns.distplot(df_copy,x=df_copy[cols[i]],bins=20)
      plt.title(f"Distribution de {cols[i]} ")
      plt.axvline(df_copy[cols[i]].mean(),color='#5784BA',linestyle='--', label='Moyenne')
      plt.axvline(df_copy[cols[i]].median(),color='#B6D8F2',linestyle='--', label='Median')
      plt.axvline(df_copy[cols[i]].quantile(q=(0.25)),color='#4A919E',linestyle='--', label='1er Quartile')
      plt.axvline(df_copy[cols[i]].quantile(q=(0.75)),color='#5784BA',linestyle='--', label='3e Quartile')
      plt.legend()
      plt.grid()
      plt.show()
```

Variable Shirt Number:

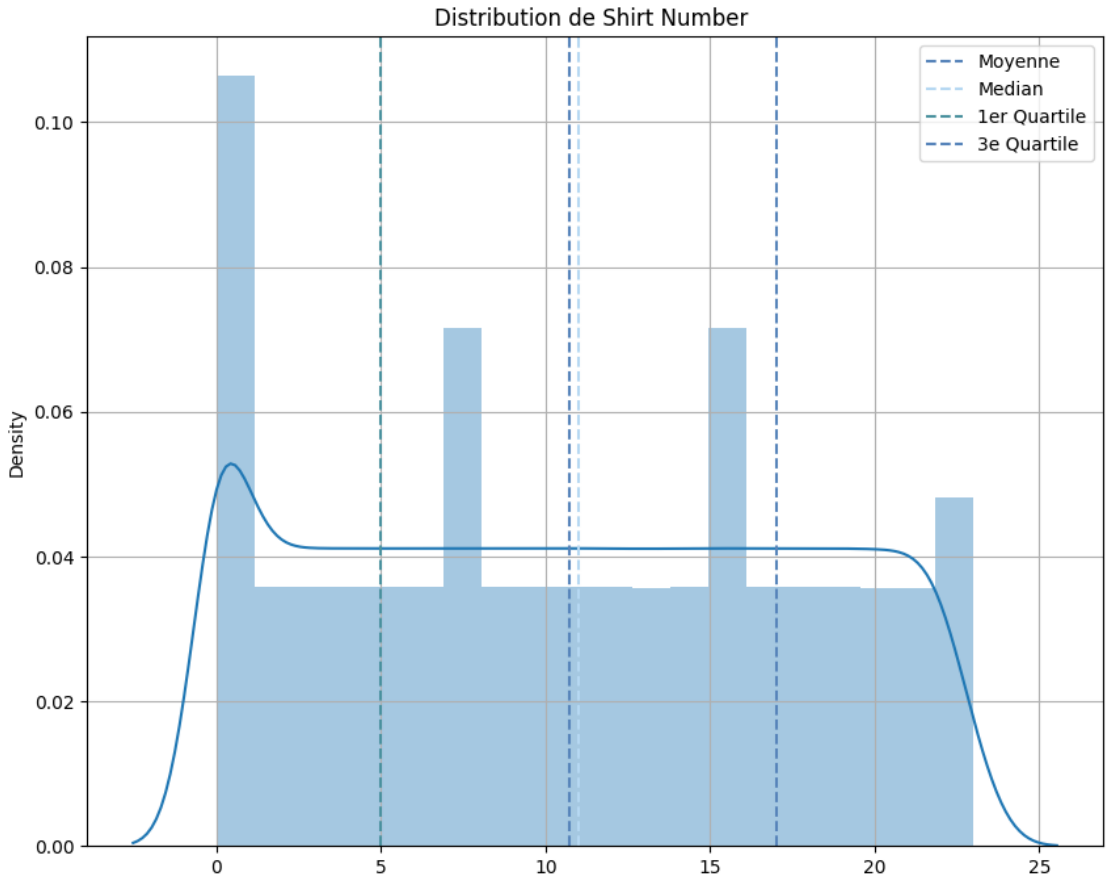

Le graphique révèle une distribution multimodale des numéros de maillot, avec plusieurs pics distincts qui montrent des groupes de numéros plus populaires, tels que 1, 10 et 20. Cette distribution peut refléter des choix traditionnels ou des conventions d'équipe, comme les numéros spécifiques aux gardiens de but ou aux attaquants. Bien que la skewness soit faible (0,03), indiquant une distribution globalement symétrique, les caractéristiques de multimodalité et la présence d'une queue visible illustrent une répartition complexe et nuancée des numéros de maillot.

Variable Event-Minute:

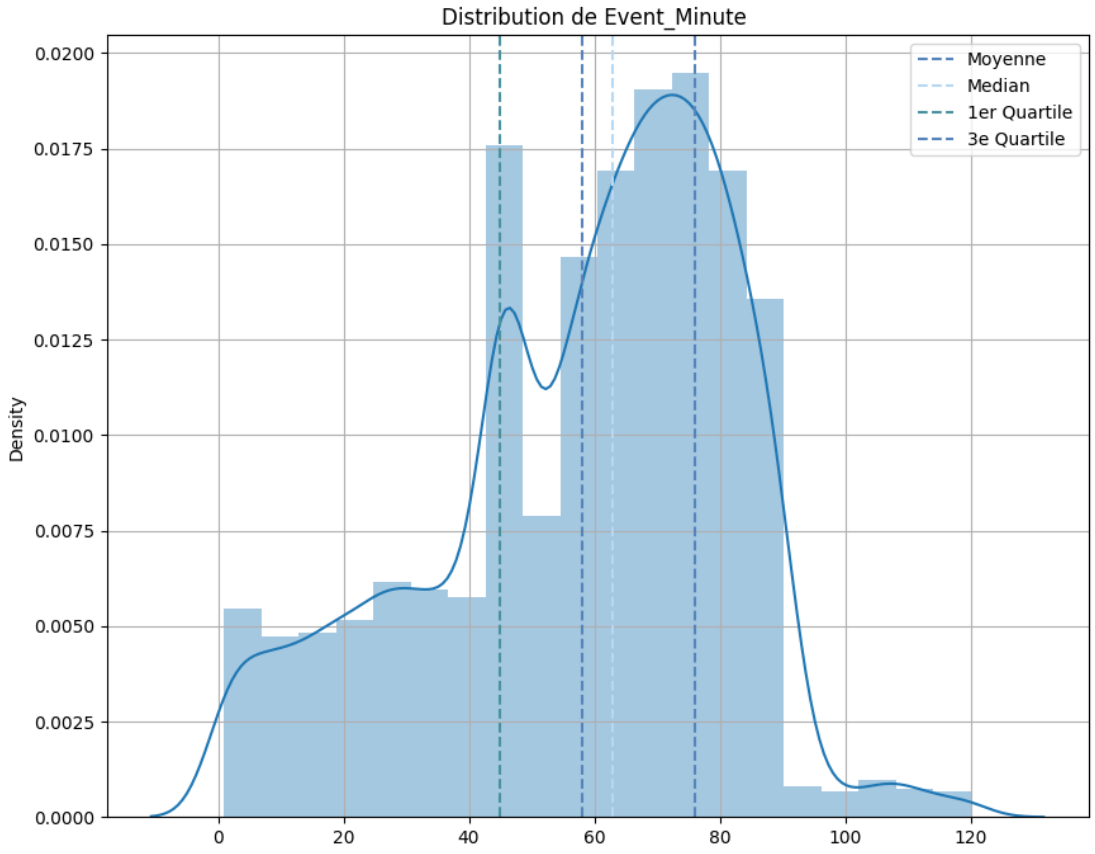

La distribution des minutes d'événements montre une concentration marquée entre 40 et 80 minutes, accompagnée d'une légère asymétrie à gauche, suggérant une tendance aux événements plus tôt dans le match. La forme étalée de la courbe (platykurtique) et sa multimodalité, avec plusieurs pics distincts, indiquent une distribution influencée par la dynamique du match, où l'intensité des événements varie selon les phases de jeu.

Analyse de la Normalité des Données : QQ-Plot Comparatif:

Variable Shirt Number:

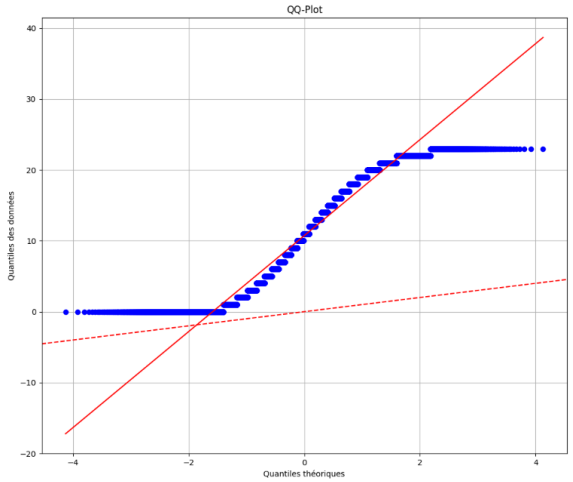


```
plt.figure(figsize=(12,10))
stats.probplot(df['Shirt Number'],dist='norm',plot=plt)
plt.title('QQ-Plot')
plt.xlabel('Quantiles théoriques')
plt.ylabel('Quantiles des données')
plt.grid(True)
plt.axline((0,0),slope=1,linestyle='--',color='red')
plt.show()
```

Interprétation des Composantes du QQ-Plot pour la Distribution des Numéros de Maillot:

Ligne Rouge Pointillée (Ligne de Référence):

- **Description** : Cette ligne rouge pointillée a une pente de 1 et passe par l'origine (0,0).
- **Rôle** : Elle sert de référence pour une distribution normale.
- **Interprétation** : Lorsque les points du QQ-plot (données observées) sont proches de cette ligne, cela suggère que les données suivent une distribution normale. Cette ligne représente donc la base de comparaison pour évaluer la normalité des données.

Ligne Bleue Continue (Ligne Ajustée):

- **Description** : Il s'agit d'une ligne bleue continue qui trace la tendance des quantiles observés.
- **Rôle** : La ligne ajustée aide à visualiser comment les quantiles observés se comparent à la ligne de référence.
- **Interprétation** : Si cette ligne bleue diverge de la ligne de référence rouge pointillée, cela indique que les données observées s'écartent d'une distribution normale, révélant des asymétries ou des particularités de la distribution des valeurs.

Ligne Rouge Solide (Ligne de Tendance ou Ajustée):

- **Description** : Cette ligne rouge solide est ajustée en fonction des quantiles observés pour tracer la tendance de ces quantiles par rapport à la normalité.
- **Rôle** : Elle fournit une estimation visuelle de l'écart entre les données et la normalité attendue.
- **Interprétation** : Si la ligne rouge solide s'éloigne de la ligne de référence pointillée, cela indique une distribution des données différente de la normale. Dans le cas des valeurs de "Shirt Number", l'écart visible suggère une concentration vers des valeurs faibles et quelques valeurs élevées, montrant que la distribution n'est pas normale.

Ces éléments révèlent que les numéros de maillot ne suivent pas une distribution normale, possiblement en raison de préférences spécifiques pour certains numéros et de la rareté des valeurs extrêmes.

Variable Event-Minute:

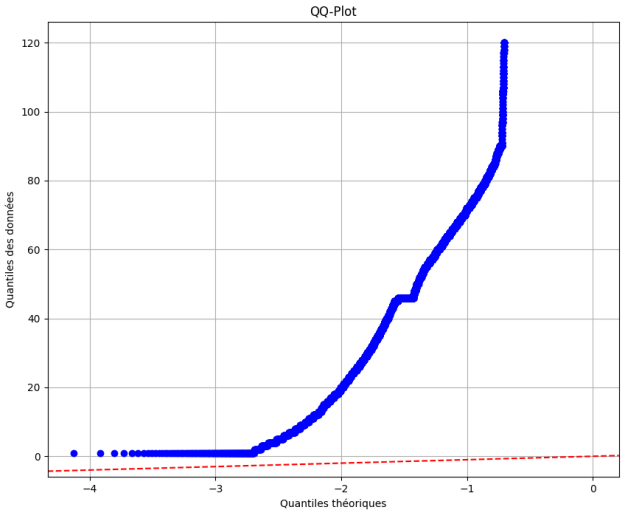


```
plt.figure(figsize=(10,8))
stats.probplot(df_copy['Event_Minute'],dist='norm',plot=plt)
plt.title('QQ-Plot')
plt.xlabel('Quantiles théoriques')
plt.ylabel('Quantiles des données')
plt.grid(True)
plt.axline((0,0),slope=1,linestyle='--',color='red')
plt.show()
```

Interprétation des Composantes du QQ-Plot pour la Distribution de Event-Minute:

Ligne Rouge Pointillée (Ligne de Référence):

- **Description** : Cette ligne rouge pointillée a une pente de 1 et passe par l'origine (0,0).
- **Rôle** : Elle sert de référence pour une distribution normale.
- **Interprétation** : En comparant les points de données à cette ligne, on évalue si les quantiles de "Event-Minute" suivent une distribution normale. Un bon alignement sur la ligne indiquerait une distribution normale.

Courbe Observée (Ligne Bleue des Points):

- **Description** : Les points bleus représentent les quantiles observés de la variable "Event-Minute" par rapport aux quantiles théoriques d'une distribution normale.
- **Interprétation** : Ici, les points s'éloignent rapidement de la ligne de référence rouge, ce qui indique que la distribution de "Event-Minute" diffère de la normale. Les points se courbent notablement, suggérant une asymétrie et potentiellement une forte concentration dans une partie spécifique des minutes de jeu.

Cette distribution indique que les événements ne sont pas uniformément répartis dans le temps et peuvent suivre une tendance distincte, possiblement liée aux moments clés dans un match

Analyse bidimentionnelle:

Méthodes de corrélation:

Pour approfondir les relations entre les différentes variables de notre base de données, nous avons entrepris une analyse bidimensionnelle corrélationnelle. Cette approche vise à identifier et quantifier les associations entre les variables afin de détecter d'éventuels liens significatifs et de mieux comprendre la structure sous-jacente des données.

```python
encoding=LabelEncoder()
df_enocded=df_copy.copy()
for col in df_enocded.select_dtypes(include=['object']):
  df_enocded[col]=encoding.fit_transform(df_enocded[col])
corr_matrix=df_enocded.corr(method='pearson')
plt.figure(figsize=(10,8))
sns.heatmap(corr_matrix , annot=True , cmap='YlGnBu',vmin=-1,vmax=1)
plt.show()
```

Dans un premier temps, nous avons procédé à un **encodage des variables catégorielles** en valeurs numériques, indispensable pour que ces variables soient compatibles avec les calculs de corrélation. Pour cela, nous avons utilisé la fonction `LabelEncoder()` de la bibliothèque `scikit-learn`. Cet encodage transforme chaque catégorie en une valeur numérique unique, permettant ainsi d'inclure des variables qualitatives dans l'analyse corrélationnelle de manière cohérente.

Pour mesurer les corrélations, nous avons appliqué les méthodes de **Pearson** et de **Spearman**, qui sont des outils statistiques complémentaires pour évaluer différentes formes de relations:

La **corrélation de Pearson** évalue la relation linéaire entre deux variables numériques. Elle est particulièrement adaptée lorsque les variables suivent une distribution normale et que la relation est linéaire. Un coefficient de Pearson proche de +1 ou -1 indique une forte corrélation positive ou négative, respectivement, tandis qu'un coefficient proche de 0 suggère une absence de relation linéaire.

La **corrélation de Spearman**, quant à elle, mesure la relation monotone, c'est-à-dire si les valeurs des variables évoluent dans le même sens sans forcément suivre une relation linéaire stricte. Spearman est utile pour les données non paramétriques ou lorsque les relations entre les variables sont non linéaires mais monotones.

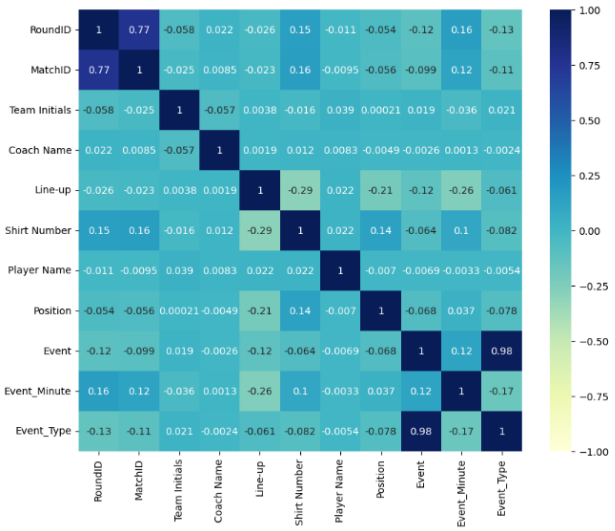

Méthode de Pearson

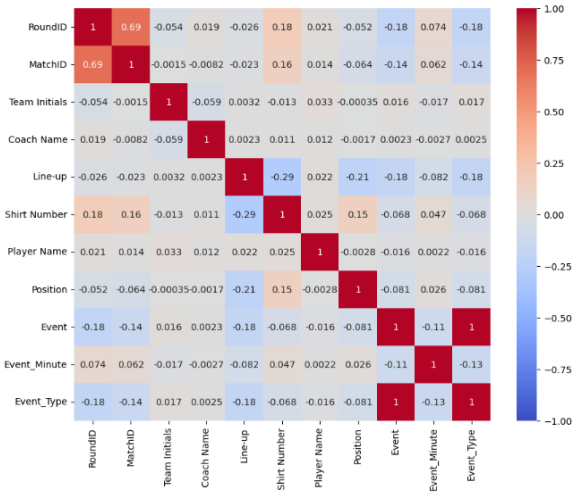

Méthode de Spearman

Les faibles corrélations obtenues suggèrent que les variables de notre base de données ne sont ni fortement linéaires (selon Pearson) ni monotones (selon Spearman). Cela peut indiquer que la relation entre ces variables est complexe, et qu'elles n'ont pas de liens simples ou évidents. Une telle situation peut résulter de relations non linéaires ou de mécanismes plus sophistiqués entre les variables, qui échappent aux tests de corrélation classiques.

Analyse des Relations entre Variables à Travers l'Information Mutuelle:

```
cols=df.select_dtypes(include=['object','int64','float64']).columns
df=df.dropna(subset=cols)
G=nx.Graph()
for col in cols:
  G.add_node(col)
for i in range(len(cols)):
  for j in range(len(cols)):
    if i!=j:
      mi_score=mutual_info_score(df[cols[i]],df[cols[j]])
      if mi_score>0:
        G.add_edge(cols[i],cols[j],weight=mi_score)
plt.figure(figsize=(10,10))
pos=nx.circular_layout(G)
edges=G.edges(data=True)
weight=[edge[2]["weight"] for edge in edges]
nx.draw(G,pos,with_labels=True, node_color='skyblue', node_size=2000, font_size=10, font_weight='bold',
        edge_color=weight, edge_cmap=plt.cm.Blues, width=3)
edge_labels={(edge[0],edge[1]):f'{edge[2]["weight"]:.2f}' for edge in edges}
nx.draw_networkx_edge_labels(G, pos, edge_labels=edge_labels, font_size=9)
plt.title("Graphe circulaire des relations entre variables (Information Mutuelle)")
plt.show()
```

Les valeurs élevées d'information mutuelle observées indiquent qu'il existe des relations significatives entre certaines variables de notre base de données, même si ces relations ne sont pas détectées par les méthodes de corrélation classiques comme les corrélations linéaires (Pearson) ou monotones (Spearman). Contrairement aux coefficients de corrélation qui ne capturent que les relations simples (linéaires ou croissantes/décroissantes constantes), l'information

mutuelle mesure la quantité totale d'information partagée entre les variables, quel que soit le type de relation.

Ce phénomène suggère que les interactions entre ces variables sont plus complexes et pourraient impliquer des relations non linéaires ou d'autres formes de dépendances que les méthodes traditionnelles de corrélation ne peuvent pas identifier. Par exemple, il pourrait s'agir de relations non symétriques, non monotones ou présentant des dépendances conditionnelles. En d'autres termes, les variables pourraient influencer l'une l'autre de manière indirecte ou selon des schémas plus subtils que ceux observés avec les mesures de corrélation conventionnelles.

Analyse des Relations entre Variables Qualitatives par le Test du Chi-2 et

Graphe circulaire des relations entre variables (Information Mutuelle)

```
cols=df.select_dtypes(include=['object']).columns
plotnumber=1
chi2_matrix=pd.DataFrame(index=cols , columns=cols)
pval_matrix=pd.DataFrame(index=cols,columns=cols)
for i in range(len(cols)):
  for j in range(len(cols)):
    if i!=j and plotnumber<=len(cols):
      tab=pd.crosstab(df[cols[i]],df[cols[j]])
      chi2 , p , dof , excepted=chi2_contingency(tab)
      chi2_matrix.iloc[i,j]=chi2
      pval_matrix.iloc[i,j]=p
labels=chi2_matrix.columns
source=[]
target=[]
value=[]
customdata=[]
for i in range(len(chi2_matrix.columns)):
  for j in range(i+1,len(chi2_matrix.columns)):
    if chi2_matrix.iloc[i,j] is not None:
      source.append(i)
      target.append(j)
      value.append(chi2_matrix.iloc[i,j])
      customdata.append((chi2_matrix.iloc[i,j],pval_matrix.iloc[i,j],labels[i],labels[j]))
fig=go.Figure(go.Sankey(
    node=dict(pad=15,
        thickness=20,
        line=dict(color="black", width=0.5),
        label=labels),
    link=dict(source=source , target=target , value=value , customdata=customdata,

    hovertemplate=(
        'Source : %{customdata[2]}<br>'
        'Target: %{customdata[3]}<br>'
        'Chi2: %{customdata[0]:.2f}<br>'
        'p-value: %{customdata[1]:.4f}<extra></extra>'
    ))
))
fig.update_layout(title_text="Diagramme de Sankey des Associations Chi-deux avec p-values, Source et Target", font_size=12)
fig.show()
```

l'Interprétation des p-values:

L'utilisation du test du Chi-2 pour analyser les relations entre différentes variables qualitatives dans notre base de données a révélé des résultats statistiquement significatifs. Un exemple typique de ces résultats est l'association entre les variables « Team Initials » et « Coach Name ». Une statistique de Chi-2 très élevée (2 749 877,55) suggère une forte différence entre les fréquences observées et attendues, indiquant une dépendance probable entre ces variables. De plus, une p-valeur extrêmement faible (0,0, généralement inférieure à 0,001) confirme la significativité

statistique de cette association, signifiant qu'il est peu probable que cette relation soit due au hasard.

Les degrés de liberté élevés (27 054) pour cet exemple, ainsi que pour d'autres relations testées, renforcent la robustesse des résultats, car ils reposent sur un grand nombre d'observations. Dans l'ensemble, ces résultats indiquent des dépendances significatives entre certaines paires de variables qualitatives dans la base de données, offrant ainsi des insights potentiels pour des analyses prédictives ou des études plus approfondies sur les liens entre ces catégories.

Évaluation de la Force des Relations entre Variables Qualitatives avec le Coefficient T de Tschuprow:

```python
cols = df_copy.select_dtypes(include='object').columns
links = []

for i in range(len(cols)):
    for j in range(i + 1, len(cols)):
        cont_tab = pd.crosstab(df_copy[cols[i]], df_copy[cols[j]])
        chi2, p, dof, expected = chi2_contingency(cont_tab)
        n = np.sum(cont_tab.values)
        r, k = cont_tab.shape
        tschuprow_t_value = np.sqrt(chi2 / (n * np.sqrt((k - 1) * (r - 1))))
        if tschuprow_t_value > 0:
            links.append((cols[i], cols[j], tschuprow_t_value))

links_df = pd.DataFrame(links, columns=['source', 'target', 'value'])
nodes = list(set(links_df['source']).union(set(links_df['target'])))

chord = hv.Chord((links_df, hv.Dataset(nodes, 'index')))
chord.opts(
    opts.Chord(labels='index', cmap='Category20', edge_color='source',
               node_color='index', width=600, height=600, edge_alpha=0.8,
               title="Diagramme de Chord de T-Tshuprow")
)

chord
```


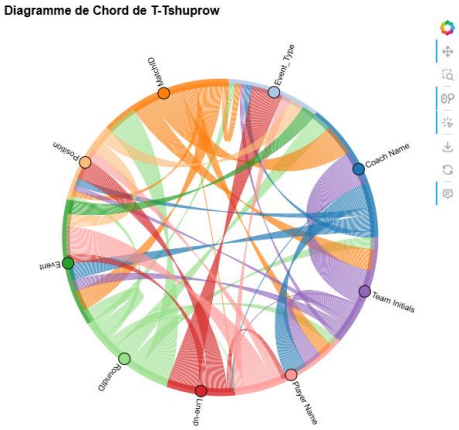

Pour mieux comprendre la force des associations entre variables qualitatives, les résultats ont été visualisés sous forme de diagramme de Chord, conçu à l'aide de la bibliothèque HoloViews. Ce type de visualisation est particulièrement utile pour représenter les relations entre différentes variables, car il illustre les associations par des liens de largeur variable : plus le lien entre deux variables est large, plus l'association entre elles est forte. Cette approche permet de saisir rapidement la force relative des relations dans un cadre visuel intuitif.

Dans l'ensemble, l'analyse révèle que la majorité des variables dans notre ensemble de données montrent des associations fortes. Ces liens dominants suggèrent que certaines variables partagent des relations significatives, potentiellement exploitables pour des modèles d'analyse plus avancés ou des études de corrélation. Le diagramme de Chord apporte une perspective claire et structurée sur ces dépendances, facilitant l'identification des variables centrales dans le réseau d'associations et permettant ainsi de mieux orienter les étapes analytiques suivantes.

Visualisation de la Distribution Conditionnelle des Événements par Équipe:

1. Utilisation de Pandas pour le Calcul de la Distribution Conditionnelle:

Pour calculer la distribution conditionnelle des données, nous avons d'abord utilisé la bibliothèque Pandas. Grâce à la fonction `pd.crosstab`, nous avons pu effectuer une normalisation des données, soit par index, soit par colonne. Cette normalisation permet de traiter chaque ligne (représentant une équipe) de manière indépendante en termes de proportions. Ainsi, chaque équipe

est évaluée en fonction de la fréquence relative des événements ou des variables d'intérêt, ce qui garantit l'obtention de résultats significatifs, robustes et comparables à travers les différentes équipes.

2. Visualisation des Données avec Plotly:

Pour la visualisation des résultats obtenus, nous avons ensuite utilisé la bibliothèque Plotly. La fonction `imshow` de Plotly a été employée pour générer une carte de chaleur, une représentation graphique efficace des données. Dans cette carte, chaque cellule est colorée selon la fréquence relative du numéro de maillot attribué à chaque équipe. Cette approche visuelle permet de repérer facilement les tendances, les anomalies et les motifs dans la répartition des numéros de maillot, facilitant ainsi une analyse rapide et intuitive des relations au sein des données.

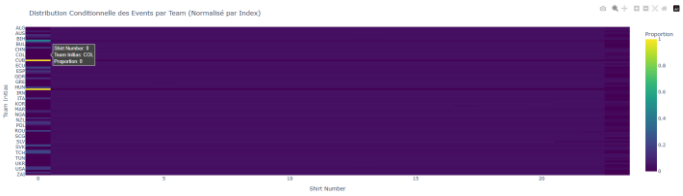

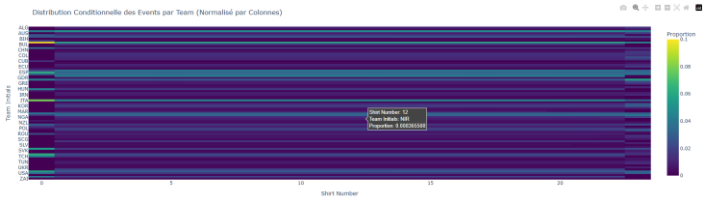

Analyse de la Distribution des Numéros de Maillot par Position des Joueurs:

```
px.box(data_frame=df,x=df['Position'] , y=df['Shirt Number'] , color =df['Position'] , template = 'plotly_dark')
```

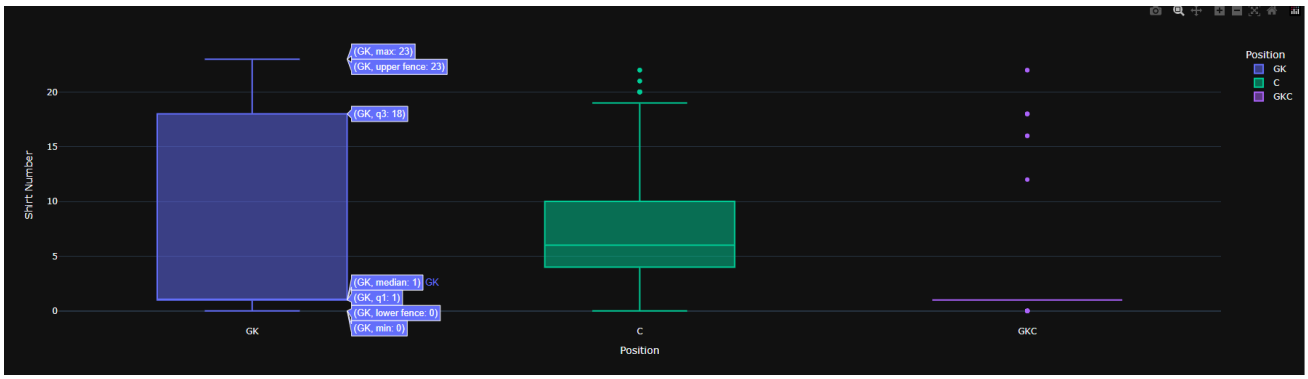

Pour analyser la distribution des numéros de maillot en fonction de la position des joueurs, nous avons utilisé la fonction `box` de la bibliothèque Plotly Express, qui permet de générer des boîtes à moustaches pour chaque catégorie en fonction des numéros de maillot attribués. Cette visualisation permet de comparer facilement la répartition des numéros de maillot entre différentes positions sur le terrain.

Les résultats montrent des différences marquées entre les positions. La répartition des numéros de maillot des gardiens de but varie largement, allant de 0 à 20, avec une médiane située autour de 12 à 13. Cette plage plus étendue reflète une plus grande flexibilité dans l'attribution des numéros pour cette position. En revanche, les joueurs centraux présentent une plage plus restreinte, avec des numéros généralement compris entre 1 et 10, et une médiane proche de 5. Il est à noter que cette catégorie présente également plusieurs outliers au-dessus de 10, suggérant des cas particuliers

pour certains joueurs. Enfin, pour la catégorie "Gardien + Centrale", les numéros de maillot sont presque constants, avec une médiane de 0, mais un outlier élevé se distingue nettement des autres, ce qui mérite une attention particulière pour comprendre cette anomalie. Cette analyse met en lumière les variations significatives dans l'attribution des numéros selon les rôles des joueurs.

Relation entre Shirt Number et Event_Minute:

```
cols=df_copy.select_dtypes(include=['int64','float64']).columns
plotnumber=1
for i in range(len(cols)):
  for j in range(len(cols)):
    if i!=j:
      fig = px.scatter(df_copy, x=cols[i], y=cols[j],
                       title=f'Relation entre {cols[i]} et {cols[j]}')
      fig.update_layout(
                xaxis_title=cols[i],
                yaxis_title=cols[j],
                width=800,
                height=600
            )
      fig.show()
```

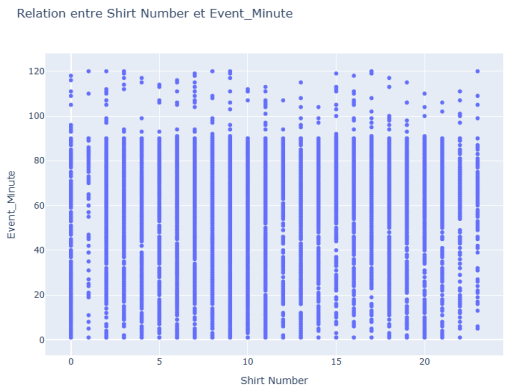

- Le graphique montre une large gamme de valeurs Event_Minute pour chaque numéro de maillot. Cela suggère que des joueurs avec différents numéros de maillot ont été impliqués dans des événements à divers moments du jeu.
- Il semble y avoir une légère concentration d'événements dans les premières minutes (0-10) pour certains numéros de maillot, ce qui indique que ces joueurs ont peut-être été impliqués dans des activités de début de jeu comme marquer des buts ou effectuer des passes clés.
- Il y a également des événements dispersés tout au long de la durée du jeu pour la plupart des numéros de maillot, ce qui suggère que ces joueurs ont été activement impliqués dans le jeu du début à la fin.
- Les joueurs avec une forte concentration d'événements dans les dernières minutes pourraient être des défenseurs ou des remplaçants qui entrent en jeu pour solidifier la défense ou changer le cours du jeu.
- Le schéma général des événements pour différents numéros de maillot pourrait fournir des informations sur l'approche tactique de l'équipe. Par exemple, une équipe qui a tendance à avoir plus d'événements dans le tiers offensif pourrait être davantage axée sur le jeu offensif.
- Nous pourrions analyser la distribution des événements pour des joueurs individuels afin de comprendre leur contribution au jeu. Les joueurs avec un nombre élevé d'événements dans des zones clés comme le tiers offensif ou la surface de réparation pourraient être considérés comme des joueurs clés.

Répartition des Types d'Événements par Équipe:

```
g = sns.FacetGrid(df_copy, col='Team Initials', col_wrap=4, height=4)
g.map(sns.countplot, 'Event_Type',palette='pastel')
g.set_titles("{col_name}")
plt.show()
```

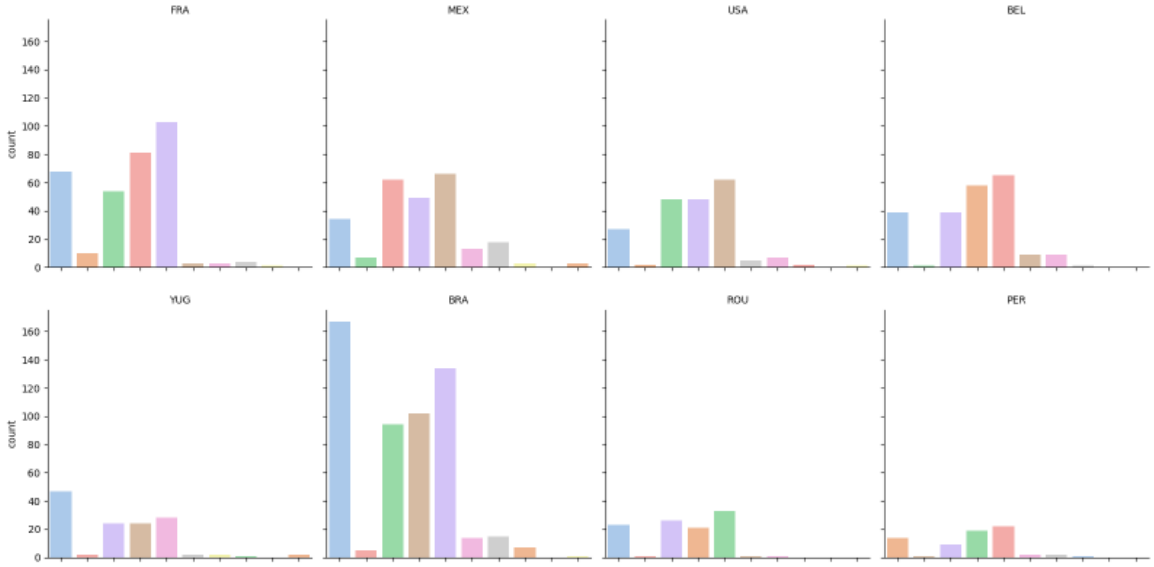

Pour analyser la répartition des types d'événements par équipe, nous avons utilisé la bibliothèque Seaborn et la méthode FacetGrid, qui permet de générer des graphiques distincts pour chaque équipe, facilitant ainsi une comparaison visuelle. Chaque sous-graphe présente un countplot, mettant en évidence le nombre d'événements par type pour chaque équipe.

L'analyse révèle que certains types d'événements sont particulièrement fréquents. En particulier, les événements de type :

- **G (Goal)** : illustrent les buts marqués par l'équipe, un indicateur clé de performance offensive ;
- **O (Offside)** : montrent les hors-jeu signalés, un aspect important de la tactique défensive et de l'organisation du jeu ;
- **I (Injury)** : indiquent les blessures subies par les joueurs, soulignant les risques et l'intensité des matchs.

Treemap des Équipes en Fonction des Entraîneurs:

Pour analyser et visualiser la répartition des équipes par entraîneur, nous avons utilisé un treemap généré avec la bibliothèque Plotly. Ce type de visualisation permet de représenter les hiérarchies de manière claire et intuitive. Dans ce treemap, chaque équipe est représentée par un rectangle

```
fig = px.treemap(df_copy, path=['Team Initials', 'Coach Name'], title='Treemap des Équipes par Coach')
fig.show()
```

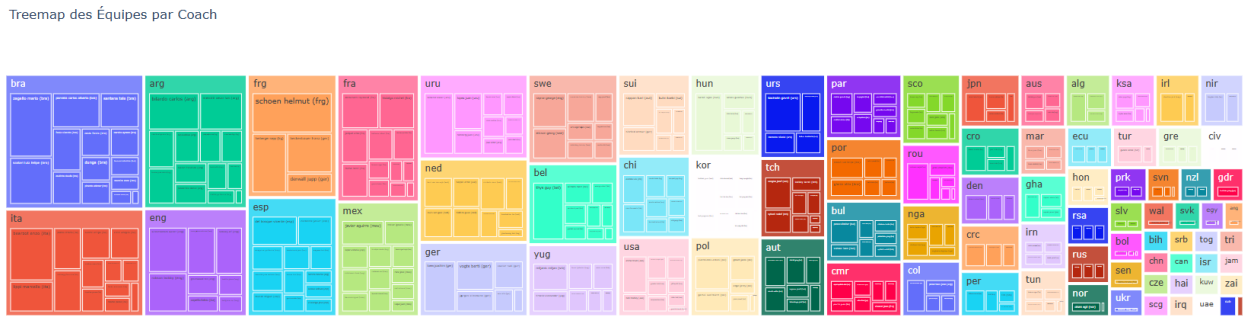

parent, et les entraîneurs associés à chaque équipe au fil du temps sont visualisés comme des éléments enfants sous chaque rectangle parent.

Chaque rectangle parent correspond donc à une équipe, tandis que les rectangles enfants, placés sous chaque équipe, illustrent les différents entraîneurs qui ont dirigé cette équipe à différentes périodes. Cette structure hiérarchique permet non seulement de visualiser les entraîneurs qui ont occupé le poste au sein de chaque équipe, mais aussi de comparer l'historique des entraîneurs entre différentes équipes. L'utilisation de cette visualisation facilite l'identification rapide des équipes ayant eu plusieurs entraîneurs, ainsi que la durée de chaque mandat. Elle permet également d'effectuer des comparaisons intéressantes sur la stabilité des équipes en termes de gestion technique et de rotation des entraîneurs.

■ Analyse multidimensionnelle:

Distribution du Numéro de Maillot par Type d'Événement et Position:

```
df_copy.dropna(subset='Event_Type')
top_value=df_copy['Event_Type'].value_counts().nlargest(10).index
df_top=df_copy[df_copy['Event_Type'].isin(top_value)]
sns.violinplot(x='Event_Type', y='Shirt Number',hue='Position',data=df_top,split=True, inner="quartile"
)
```

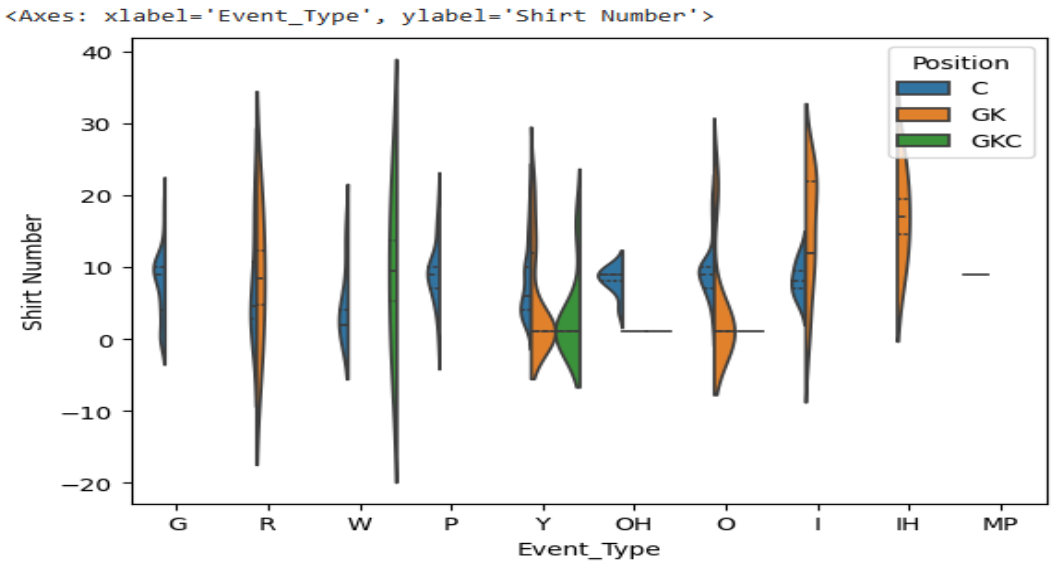

cette visualisation permet de comparer la répartition des numéros de maillot selon les différents types d'événements et les positions des joueurs, tout en mettant en avant les types d'événements les plus fréquents. Elle permet de voir si certaines positions ou certains numéros de maillot sont plus fréquents pour des types d'événements particuliers.

- La forme des violons donne une idée de la distribution des numéros de maillot pour chaque type d'événement et pour chaque position.
- Les parties plus larges des violons indiquent des valeurs plus fréquentes pour les numéros de maillot.
- Les lignes de quartile internes indiquent la répartition des valeurs et aident à identifier la médiane et la variation des numéros de maillot pour chaque catégorie.

Distribution des Numéros de Maillot selon le Line-up et la Position:

```
sns.catplot(data=df_top,x='Line-up',y='Shirt Number',hue='Position', kind='box',palette="Set2")
```

```
<seaborn.axisgrid.FacetGrid at 0x7aa4424e6c20>
```

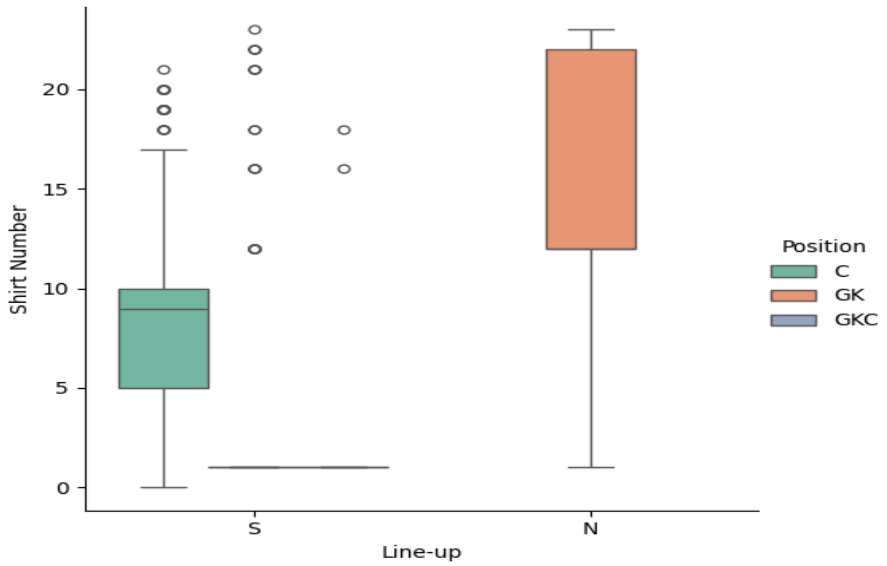

cette visualisation permet de comprendre la distribution des numéros de maillot en fonction des différents types de "Line-up" et de position des joueurs. Elle montre comment les numéros de maillot varient entre les positions et les types de "Line-up", en soulignant les valeurs typiques ainsi que les exceptions.

- Chaque boîte indique la répartition des numéros de maillot pour une position donnée dans un type de "Line-up".
- La ligne noire au centre de chaque boîte représente la médiane des numéros de maillot pour cette position et ce type de "Line-up".
- Les parties supérieures et inférieures de la boîte indiquent le premier et le troisième quartiles, tandis que les "moustaches" (les lignes qui s'étendent au-dessus et en dessous des boîtes) montrent l'étendue des données, excluant les valeurs extrêmes (ou outliers).
- Les points situés en dehors des "moustaches" représentent des valeurs extrêmes (outliers), ce qui signifie des numéros de maillot qui sont significativement plus élevés ou plus bas par rapport à la majorité des données.

Distribution du nombre d'événements par joueur et par équipe:

```python
#Nuage de points du nombre d'événements par joueur et par équipe

import plotly.express as px

df_events_by_player = df_players.groupby(['Player Name', 'Team Initials'])['Event'].count().reset_index()

fig = px.scatter(df_events_by_player, x='Player Name', y='Event',
                 color='Team Initials', size='Event',
                 title="Nombre d'événements par joueur et par équipe",
                 labels={'Event': "Nombre d'événements"})
fig.show()
```

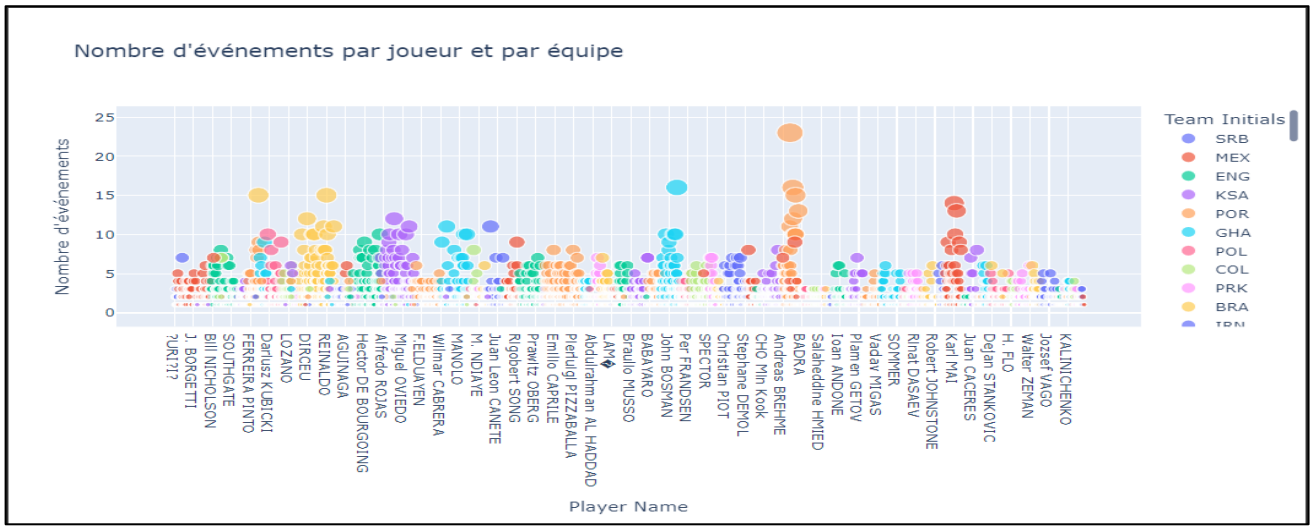

cette visualisation permet de voir la distribution du nombre d'événements par joueur et par équipe. Elle aide à identifier les joueurs les plus impliqués dans les événements et à comparer l'activité entre différentes équipes. Ce graphique est particulièrement utile pour observer des tendances et des comparaisons dans la participation des joueurs aux événements.

- **Distribution des événements par joueur et par équipe :**

- Le graphique montre des différences significatives entre les joueurs et les équipes en termes de participation aux événements.
- Les équipes avec de nombreux points de grande taille suggèrent une forte participation de certains joueurs à des événements.
- Les joueurs ayant de nombreux événements sont facilement repérables grâce à la taille et à la position en hauteur des points.

4. Etude avec Scala sur la dataset “WorldCupPlayers.csv”

- Analyse unidimensionnelle:

Présentation du dataset:

```
import $ivy.`org.apache.spark::spark-core:3.5.3`
import $ivy.`org.apache.spark::spark-sql:3.5.3`
✓ [6] 4s 730ms
import $ivy.$
import $ivy.$

import org.apache.spark.sql.SparkSession
✓ [7] 2s 439ms
import org.apache.spark.sql.SparkSession

val spark = SparkSession.builder()
  .appName("My Spark Application")
  .config("spark.master", "local")
  .getOrCreate()
spark.sparkContext.setLogLevel("ERROR")
✓ [8] 2s 169ms
spark: SparkSession = org.apache.spark.sql.SparkSession@3d74557a
{} Code  M↓ Markdown
var df_matches = spark.read.format("csv").option("header", "true").load("WorldCupMatches.csv")
```

On commence par configurer un environnement Spark local. On crée un `SparkSession` pour interagir avec Spark et charger notre dataSet `WorldCupMatches.csv` dans un DataFrame. Le niveau de Log est réglé sur "ERROR" pour réduire la verbosité.

```
df_matches.describe().show()
✓ [10] 2s 702ms
5 rows  5 rows × 21 columns  Static Output
```

summary	Year	Datetime	Stage	Stadium	City	Home Team Nam
count	852	852	852	852	852	852
mean	1985.0892018779343	NULL	NULL	NULL	NULL	NULL
stddev	22.448824702022502	NULL	NULL	NULL	NULL	NULL
min	1930	01 Jul 1950 - 15:00	Final	Arena Amazonia	Alicante	"rn"">Bosnia a
max	2014	31 May 2002 - 20:30	Third place	Zentralstadion	Zurich	Zaire

En utilisant `describe().show()` on trouve des statistiques résumées pour le DataFrame. On y trouve des informations sur le nombre d'entrées (count), la moyenne (mean), l'écart type (stddev), ainsi que les valeurs minimales (min) et maximales (max) pour chaque colonne. Cette sortie permet d'obtenir une vue d'ensemble de la distribution des données numériques.

Nettoyage de données:

```
import org.apache.spark.sql.functions._
✓ [11] 2s 756ms
import org.apache.spark.sql.functions._

df_matches = df_matches.withColumn("Year",col("Year").cast("integer"))
df_matches = df_matches.withColumn("Attendance",col("Attendance").cast("integer"))
df_matches = df_matches.withColumn("Half-time Home Goals",col("Half-time Home Goals").cast("integer"))
df_matches = df_matches.withColumn("Half-time Away Goals",col("Half-time Away Goals").cast("integer"))
df_matches = df_matches.withColumn("Home Team Goals",col("Home Team Goals").cast("integer"))
df_matches = df_matches.withColumn("Away Team Goals",col("Away Team Goals").cast("integer"))
```

convertit les colonnes `Year`, `Attendance`, ainsi que les colonnes liées aux buts en entiers, en utilisant la fonction `cast("integer")`. Cette conversion est cruciale pour garantir que les données sont correctement traitées lors de calculs.

- Analyse unidimensionnelle:

Variable quantitative: *Attendance*

```
val attStats = df_matches.agg(min("Attendance").as("Min"),max("Attendance").as("Max"),avg("Attendance")
 .as("Mean"),stddev("Attendance").as("Ecart type"),
  variance("Attendance").as("Variance"),skewness("Attendance").as("Skewness"),kurtosis("Attendance").as
   ("Kurtosis"))
val mode = df_matches.groupBy("Attendance").agg(count("Attendance").alias("Count")).orderBy(desc
("Count")).limit(1)

val quantiles = df_matches.stat.approxQuantile("Attendance", Array(0.25, 0.5, 0.75), 0.01)

val attStatsRes = attStats.collect()(0)
val modeResult = mode.collect()(0)
println(s"Min Attendance: ${attStatsRes.getAs[Int]("Min")}")
println(s"Max Attendance: ${attStatsRes.getAs[Int]("Max")}")
println(s"Mean Attendance: ${attStatsRes.getAs[Double]("Mean")}")
println(s"Standard Deviation: ${attStatsRes.getAs[Double]("Ecart type")}")
println(s"Variance: ${attStatsRes.getAs[Double]("Variance")}")
println(s"Mode Attendance: ${modeResult.getAs[Int]("Attendance")} (Count: ${modeResult.getAs[Long]
 ("Count")})")
println(s"Skewness: ${attStatsRes.getAs[Double]("Skewness")}")
println(s"Kurtosis: ${attStatsRes.getAs[Double]("Kurtosis")}")
println(s"25th Quantile: ${quantiles(0)}")
println(s"50th Quantile (Median): ${quantiles(1)}")
println(s"75th Quantile: ${quantiles(2)}")
```

On calcule les mesure statistiques sur la colonne "Attendance", telles que la valeur minimale, maximale, la moyenne, l'écart type, la variance, la skewness, la kurtosis, ainsi que le mode et les quantiles (25, 50 et 75 percentiles.

```
75th Quantile: 60790.0Min Attendance: 2000
Max Attendance: 173850
Mean Attendance: 45164.8
Standard Deviation: 23485.249247289277
Variance: 5.515569322073016E8
Mode Attendance: 43000 (Count: 13)
Skewness: 0.8174563980655211
Kurtosis: 1.621558055150354
25th Quantile: 29800.0
50th Quantile (Median): 41000.0
75th Quantile: 60790.0
```

Min et Max : Attendance varie de 2 000 à 173 850, ce qui suggère une large gamme de valeurs.

Moyenne : La moyenne de l'assistance est de 45 164.8, ce qui montre une tendance centrale relativement élevée.

Écart-type : L'écart type dans les résultats est de 23 485,25. Cela indique une grande dispersion des valeurs d'assistance autour de la moyenne de 45 164.8.

Mode : La valeur de mode est 43 000, indiquant que l'assistance la plus fréquente est de 43 000, avec 13 occurrences.

Skewness et Kurtosis : La skewness de 0,82 indique que la distribution est légèrement asymétrique vers la droite (avec plus de valeurs faibles), tandis que la kurtosis de 1,62 suggère une distribution modérément aplatie par rapport à une distribution normale, avec des valeurs moins extrêmes.

Quantiles : Les quantiles montrent que 25 % des événements ont une attendance inférieure à 29 800, 50 % (médiane) ont une attendance inférieure à 41 000, et 75 % ont une attendance inférieure à 60 790. Cela montre qu'une grande majorité des événements se situent en dessous de 60 000 participants, avec des valeurs plus élevées correspondant à un petit nombre d'événements.

Boite a moustache:

Plotly:

```
import $ivy.`org.plotly-scala::plotly-almond:0.8.5`
✓ [16] 1s 656ms
 import $ivy.$

import plotly._
import plotly.element._
import plotly.layout._
import plotly.Almond._
import spark.implicits._
```

On importe Plotly pour créer des visualisations interactives.

```
val attendanceData = df_matches.withColumn("Attendance", col("Attendance").cast("int"))

val filteredAttendanceData = attendanceData.filter(col("Attendance").isNotNull)

val attendanceList = filteredAttendanceData.select("Attendance").as[Int].collect().toSeq

val boxPlot = Box(
  y = attendanceList,
  boxpoints = BoxPoints.All,
  name = "Attendance"
)
boxPlot.plot()
```

On commence par filtrer les valeurs nulles pour ne conserver que les lignes avec des données valides. Ensuite, il collecte les valeurs d'attendance sous forme de séquence et génère un **boxplot** pour illustrer la distribution de ces données.

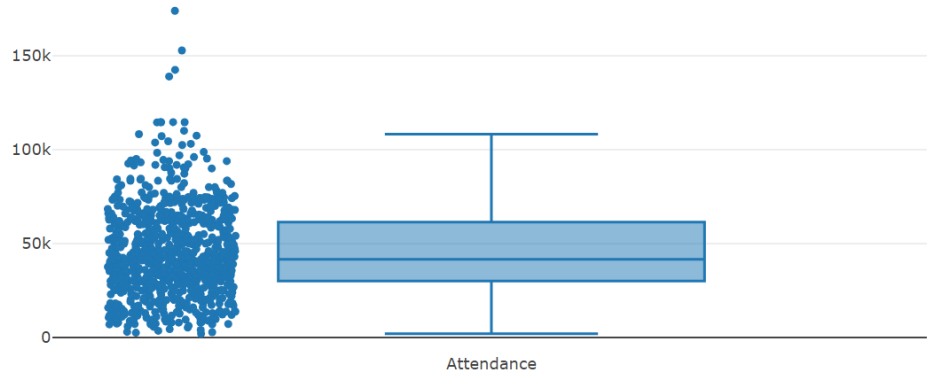

Identification des outliers:

Ce code permet d'identifier les valeurs aberrantes (outliers) en utilisant la méthode de l'écart interquartile (IQR).

Year	Home Team Name	Away Team Name	Stage	Attendance
1950	Brazil	Yugoslavia	Group 1	142429
1950	Brazil	Sweden	Group 6	138886
1950	Brazil	Spain	Group 6	152772
1950	Uruguay	Brazil	Group 6	173850
1970	Mexico	Belgium	Group 1	108192
1970	Brazil	Italy	Final	107412
1986	Belgium	Mexico	Group B	110000
1986	Mexico	Paraguay	Group B	114600
1986	Mexico	Bulgaria	Round of 16	114580
1986	Argentina	England	Quarter-finals	114580
1986	Argentina	Belgium	Semi-finals	114500
1986	Argentina	Germany FR	Final	114600

les outliers concernant l'attendance à des matchs de la Coupe du Monde, avec des chiffres exceptionnellement élevés. Ces assistances particulièrement élevées, comme celles observées lors des matchs Brésil vs Espagne (1950) avec 152 772 spectateurs ou Uruguay vs Brésil (1950) avec

173 850 spectateurs, reflètent des événements historiques marquants, souvent liés à des matchs de phase finale ou des compétitions très médiatisées. Les stades de l'époque, comme le Maracanã au Brésil, avaient des capacités bien plus grandes que ceux utilisés lors des éditions modernes, ce qui explique ces chiffres élevés.

Variable qualitative: *Stage*

Calcul des fréquences:

```
val stageCounts = df_matches.groupBy("Stage").count().orderBy(desc("count"))
stageCounts.show()
✓ [21] 3s 662ms
|             Group A|   60|
|             Group B|   60|
|             Group 2|   59|
|             Group 3|   56|
|             Group 4|   55|
|             Group E|   48|
|             Group D|   48|
|             Group F|   48|
|             Group C|   48|
|         Semi-finals|   36|
|             Group H|   30|
|             Group G|   30|
|               Final|   20|
|Match for third p...|   15|
|             Group 6|   12|
|         First round|    9|
|   Preliminary round|    8|
+--------------------+-----+
```

On calcule le nombre de matchs dans chaque phase de la coupe du monde.Les résultats montrent la répartition du nombre de matchs par phase dans le tournoi, avec des variations selon les étapes de la compétition. La phase des huitièmes de finale (Round of 16) enregistre le plus grand nombre de matchs (72), suivie des quarts de finale (66 matchs) et des groupes qui comptent entre 48 et 62 matchs selon le groupe. Les phases suivantes, comme les demi-finales et la finale, comptent moins de matchs (respectivement 36 et 20), ce qui est logique étant donné le format du tournoi à élimination directe. Les phases préliminaires et le premier tour comptent également un nombre réduit de matchs (8 et 9).

Fréquence absolue et relative:

```
val totalMatches = df_matches.count()
val stageWithRelativeFreq = stageCounts.withColumn("Relative Frequency", col("count") / totalMatches
.toDouble)
stageWithRelativeFreq.show()
✓ [22] 2s 626ms
```

```
+--------------------+-----+--------------------+
|               Stage|count|  Relative Frequency|
+--------------------+-----+--------------------+
|         Round of 16|   72| 0.08450704225352113|
|      Quarter-finals|   66| 0.07746478873239436|
|             Group 1|   62| 0.07276995305164319|
|             Group A|   60| 0.07042253521126761|
|             Group B|   60| 0.07042253521126761|
|             Group 2|   59| 0.06924882629107981|
|             Group 3|   56| 0.06572769953051644|
|             Group 4|   55| 0.06455399061032864|
|             Group E|   48|0.056338028169014086|
|             Group D|   48|0.056338028169014086|
|             Group F|   48|0.056338028169014086|
|             Group C|   48|0.056338028169014086|
```

En examinant les résultats, on constate que les étapes comme les "Round of 16" et les phases de groupe (par exemple, "Group A", "Group B") occupent une grande partie des matchs, avec des fréquences relatives respectivement autour de 8,4% et 7%. Les étapes plus avancées, comme les quarts de finale, les demi-finales et la finale, ont des fréquences beaucoup plus faibles, ce qui reflète la nature éliminatoire des compétitions. Les étapes moins courantes, telles que la "Preliminary round" ou le "Match for third place", ont des fréquences relativement faibles, montrant qu'elles concernent moins de matchs.

Mode:

```
val modeStage = stageCounts.first()
println(s"Le mode de la variable 'Stage' est : ${modeStage.getString(0)} avec ${modeStage.getLong(1)}
 matchs.")
✓ [23] 1s 770ms
```

```
Le mode de la variable 'Stage' est : Round of 16 avec 72 matchs.Le mode de la variable 'Stage' est :
  Round of 16 avec 72 matchs.
```

Le code permet de calculer le mode c'est-à-dire la phase qui a le plus grand nombre de matchs. En utilisant la méthode en afficheant que le mode de la variable "Stage" est "Round of 16" (huitièmes de finale), avec 72 matchs. Cette phase est donc celle qui regroupe le plus grand nombre de matchs.

Visualisation:

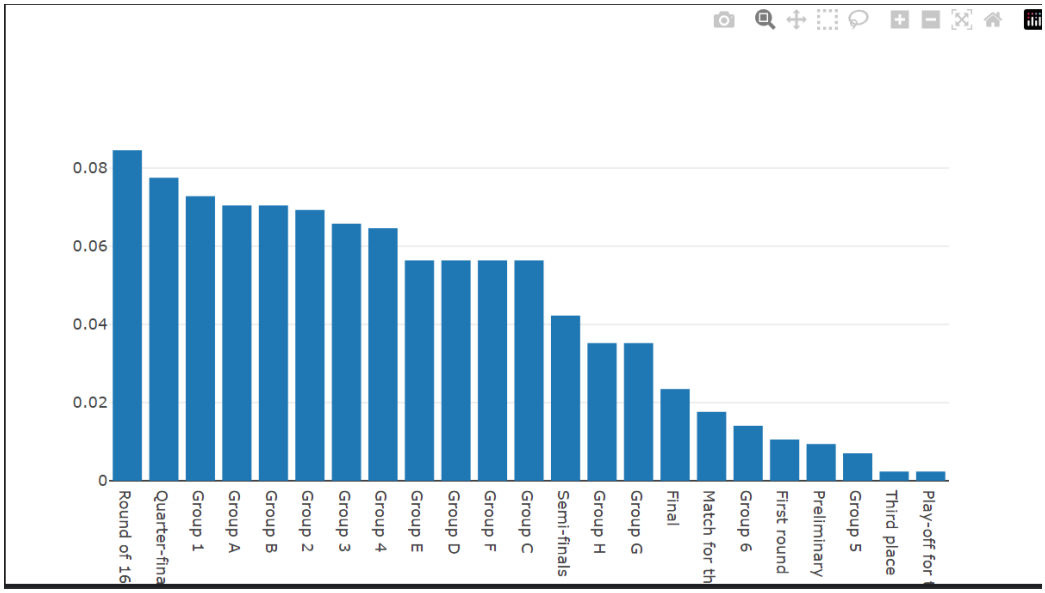

Le graphique en barres (`barplot`) est généré pour visualiser la fréquence relative de chaque phase. Les résultats montrent que la phase **"Round of 16"** (huitièmes de finale) a la plus grande fréquence relative (8,45 %), suivie des **"Quarter-finals"** (7,74 %) et des **"Group 1"**, **"Group A"**, et **"Group B"** avec des fréquences similaires (7,27 % à 7,04 %). Les phases comme la **"Final"** (2,35 %) et les **"Play-off for third place"** (0,23 %) représentent des fréquences relativement faibles.

- Analyse bidimensionnelle:

Attendance vs buts marqués:

```
val dfWithGoals = df_matches.withColumn("Total Goals", col("Home Team Goals") + col("Away Team Goals"))
val selectedDF = dfWithGoals.select("Attendance", "Total Goals").na.drop()
selectedDF.show(5)
✓ [30] 2s 149ms
```

On crée un DataFrame avec une nouvelle colonne, "Total Goals", qui représente la somme des buts marqués par les deux équipes opposée pour chaque match. Ensuite,on sélectionne uniquement les colonnes "Attendance" et "Total Goals", tout en supprimant les lignes contenant des valeurs nulles pour ces colonnes.

Correlation:

```
val correlation = selectedDF.stat.corr("Attendance", "Total Goals")
println(s"Correlation is: $correlation")

✓ [33] 1s 73ms
Correlation is: -0.11360301447979772Correlation is: -0.11360301447979772
correlation: Double = -0.11360301447979772
```

On calcule la corrélation entre deux variables, "Attendance" et "Total Goals" on une corrélation de -0.1136, indique une très faible corrélation négative entre ces deux variables, suggérant qu'il n'y a pas de lien linéaire significatif entre l'attendance des matchs et le nombre de buts marqués. Autrement dit, les matchs avec une plus grande attendance ne sont pas nécessairement associés à un nombre plus élevé de buts.

- Visualisation:

Scatter plot:

```
import $ivy.`org.scalanlp::breeze:1.2`
import $ivy.`org.scalanlp::breeze-viz:1.2`
import breeze.plot._
import breeze.linalg._
✓ [35] 3s 137ms
import $ivy.$
import $ivy.$
import breeze.plot._
import breeze.linalg._
{} Code  M↓ Markdown
val attendance = selectedDF.select("Attendance").collect().map(_.getInt(0))
val totalGoals = selectedDF.select("Total Goals").collect().map(_.getInt(0))
val attendanceVec = DenseVector(attendance.map(_.toDouble))
val totalGoalsVec = DenseVector(totalGoals.map(_.toDouble))
```

On utilise la bibliothèque **Breeze** pour visualiser le nuage de points entre les colonnes "Attendance" (participation) et Total Goals (nombre total de buts) qui sont extraites et converties en vecteurs `DenseVector`.

```
val fig = Figure()
val plt = fig.subplot(0)
plt += plot(attendanceVec, totalGoalsVec, '+', colorcode = "blue")
plt.xlabel = "Attendance"
plt.ylabel = "Total Goals"
plt.title = "Scatter Plot of Attendance vs Total Goals"
fig.refresh()
```

On crée alors le graphe de nuage de points.

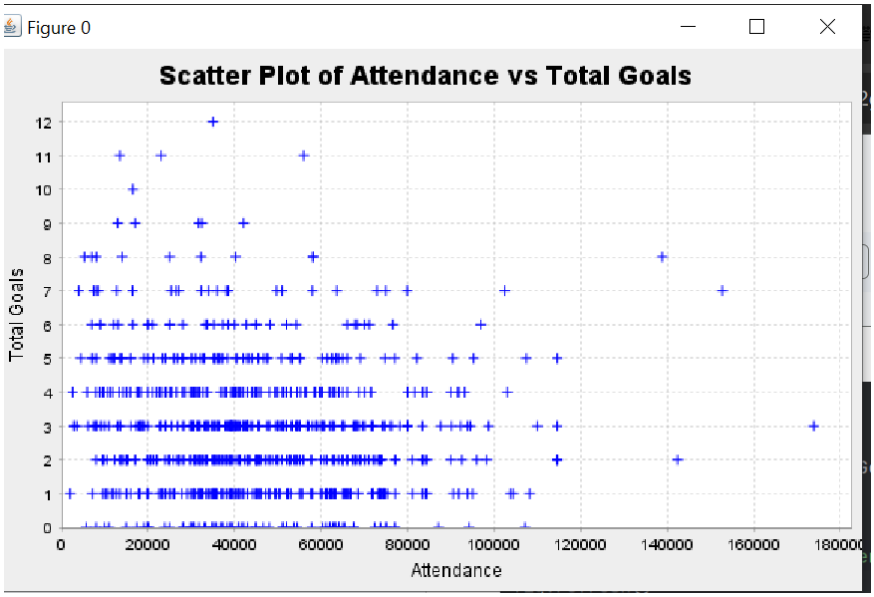
Figure 0
Scatter Plot of Attendance vs Total Goals
Total Goals
Attendance
0
1
2
3
4
5
6
7
8
9
10
11
12
0
20000
40000
60000
80000
100000
120000
140000
160000
180000

5. Conclusion:

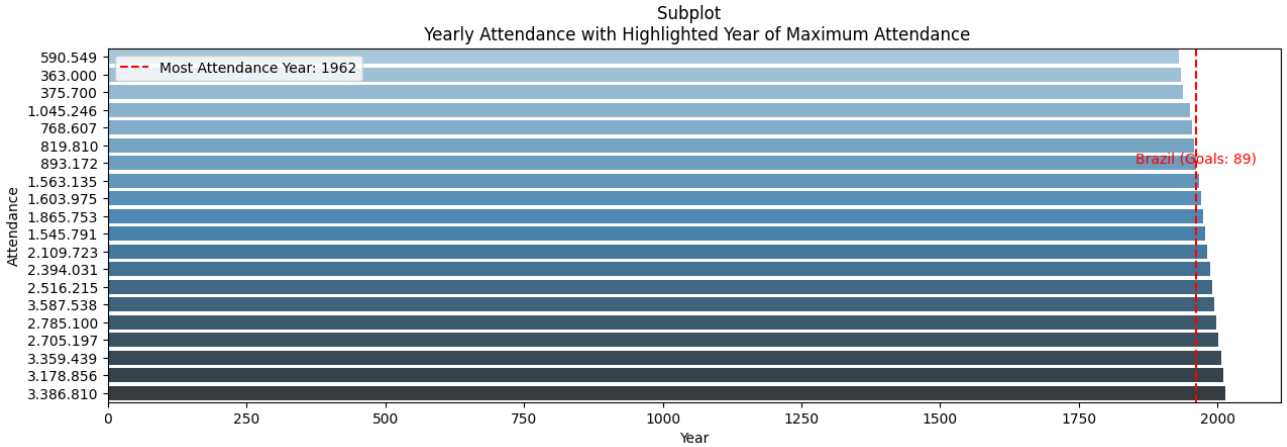

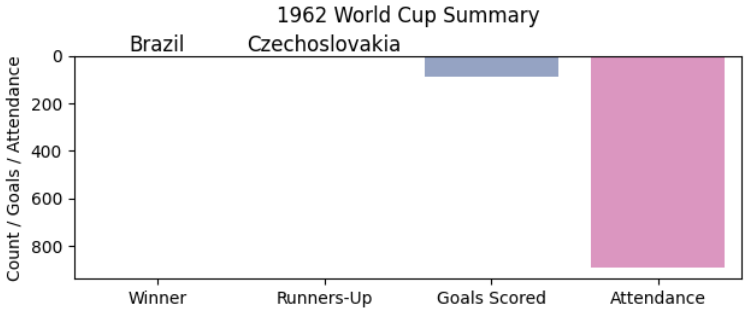

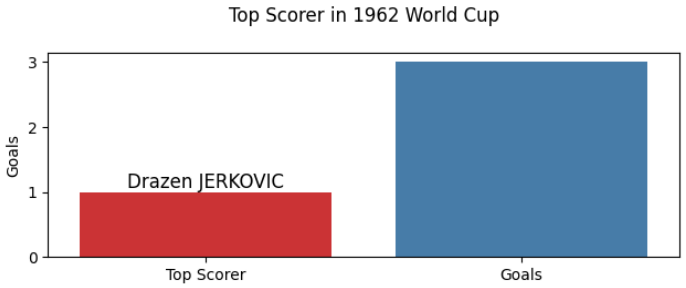

1. Graphique en haut - Fréquentation annuelle avec année de fréquentation maximale mise en évidence :

Ce graphique représente la fréquentation annuelle de la Coupe du Monde au fil des années. La barre la plus haute, marquée par une ligne rouge, indique l'année avec la fréquentation la plus élevée, en 1962. Cette année-là, il y a eu une fréquentation maximale de 3,868,810 spectateurs, ce qui en fait une année record pour la compétition.

2. Graphique en bas à gauche - Résumé de la Coupe du Monde de 1962 :

Ce graphique montre des informations clés sur le tournoi de 1962, y compris le vainqueur (Brésil), le finaliste (Tchécoslovaquie), le nombre de buts marqués, et la fréquentation. Le Brésil est souligné comme le vainqueur, et la Tchécoslovaquie est marquée comme finaliste. La barre d'assistance indique également une fréquentation élevée, en phase avec le record mentionné dans le graphique précédent.

3. Graphique en bas à droite - Meilleur buteur de la Coupe du Monde de 1962 :

Ce dernier graphique met en lumière Drazen Jerkovic, le meilleur buteur du tournoi en 1962. La hauteur de la barre montre le nombre de buts marqués par Jerkovic, soulignant son rôle de meilleur buteur avec un total de 5 buts.

➔ En résumé, ces graphiques illustrent la forte popularité de la Coupe du Monde de 1962, marquée par une fréquentation record, la victoire du Brésil, et la performance remarquable de Drazen Jerkovic comme meilleur buteur.